genie

Genie: Generative Interactive Environments

1. Introduction

기존 생성형 AI의 한계

최근 생성형 AI는 텍스트, 이미지, 영상까지 생성할 수 있을 정도로 발전함

예를 들어

- 언어 모델: 자연스러운 문장 생성
- 이미지 생성 모델: 텍스트를 보고 이미지 생성
- 영상 생성 모델: 앞부분이나 텍스트를 보고 영상 생성

하지만 기존 영상 생성 모델에는 중요한 한계가 있음. = **사용자가 생성된 세계 안에 직접 들어가서 행동하기 어려움.**

일반적인 영상 생성 모델은 `이 장면 다음에 어떤 영상이 이어질까?` 를 예측하는 모델에 가까움

반면 게임 같은 환경은 `내가 왼쪽 버튼을 누르면 어떻게 변하지?` , `점프하면 다음 장면은 어떻게 되지?` 처럼 **사용자의 행동에 따라 다음 상태가 달라져야 함**

즉, 단순한 영상 생성과 **상호작용 가능한 환경 생성**은 서로 다른 문제임.

기존 World Model의 문제

이런 식으로 **현재 상태 + 행동 → 다음 상태**를 예측하는 모델을 보통 **World Model**이라고 함.

예를 들어 게임에서 현재 화면 + 오른쪽 이동 → 캐릭터가 오른쪽으로 이동한 다음 화면을 예측하는 것

문제는 기존 World Model을 학습하려면 일반적으로 영상뿐 아니라 **실제로 어떤 행동을 했는지에 대한 action label**이 필요함

예:

```
frame 1 → action = right → frame 2
```

```
frame 2 → action = jump → frame 3
```

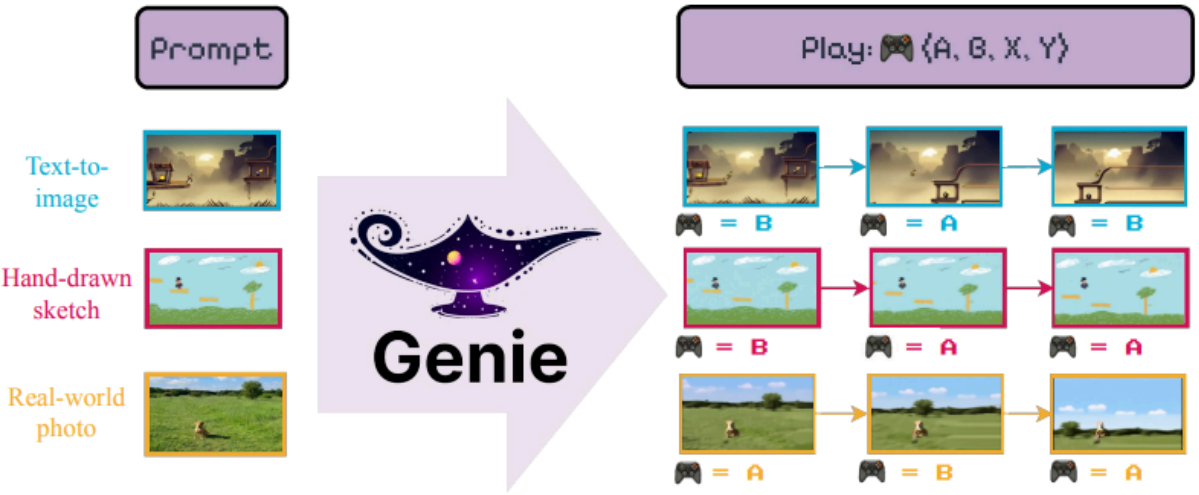
그런데 인터넷 영상에는 화면은 있어도

```
이 순간 사용자가 오른쪽 버튼을 눌렀다
```

라는 정보가 대부분 없음.

따라서 인터넷에 존재하는 엄청난 양의 영상을 World Model 학습에 그대로 사용하기 어려움.

Genie의 아이디어



Genie는 이 문제를 다음과 같이 바꿈.

⇒ 행동 라벨이 없다면, 영상 속 변화만 보고 행동 자체를 모델이 스스로 찾아내게 하면 되지 않을까?

즉 프레임 1 → 프레임 2를 관찰해서 `이 변화는 행동 A 때문인 것 같다`라는 잠재 행동(latent action)을 스스로 만들어냄.

→ 그리고 이 잠재 행동을 이용하여

```
현재 화면 + latent action → 다음 화면
```

을 생성

결과적으로 학습할 때는 **영상만 필요하지만**, 학습이 끝난 뒤에는 사용자가 행동을 선택해서 세계를 조작할 수 있게 됨.

Genie가 기존 모델과 다른 점

모델	학습 데이터	조작 수준
World Model	Video + Action	프레임 단위
Video Model	Video + Text	영상 단위
Genie	Video only	프레임 단위

= Genie는 **행동 라벨 없이 영상만 학습했는데도 프레임 단위 조작이 가능**

데이터와 모델 규모

처음에는 공개된 인터넷 게임 영상 약 20만 시간 이상을 수집하고 필터링했으며, 실제 주요 Genie 학습에는 약 30,000시간의 2D 플랫폼 게임 영상을 사용함.

최종 모델은 약 11B, 즉 110억 개 수준의 파라미터를 가짐.

텍스트, 손그림, 실제 사진 등 학습 데이터와 상당히 다른 이미지 하나를 시작 화면으로 줘도 이를 게임 같은 환경으로 만들어 조작할 수 있음

---

2. Methodology

전체흐름:

```
영상
 ↓
Video Tokenizer
 ↓
영상 토큰 z

영상
 ↓
Latent Action Model
 ↓
잠재 행동 a

영상 토큰 z + 잠재 행동 a
 ↓
Dynamics Model
 ↓
다음 프레임 예측
```

Genie는 크게 세 부분으로 이루어짐.

1. **Video Tokenizer**

   영상을 작은 이산 토큰으로 압축

2. **Latent Action Model**

   프레임 사이에서 어떤 행동이 일어났는지를 자동으로 찾음.

3. **Dynamics Model**

   지금까지의 영상과 행동을 보고 다음 화면을 생성

ST-Transformer

Genie의 거의 모든 구성요소에는 **Spatiotemporal Transformer, ST-Transformer**가 사용됨.

영상은 일반 텍스트보다 훨씬 많은 토큰을 가짐. 예를 들어 이미지 한 장에도 수많은 위치가 존재하고, 영상은 이런 이미지가 시간 순서대로 여러 장 이어짐.

= 일반 Transformer에서 모든 토큰이 서로 Attention을 수행하면 계산량이 매우 커짐.

그래서 Genie는 공간과 시간을 나누어 Attention함.

1) Spatial Attention

한 프레임 내부의 위치끼리 관계를 봄.

```
현재 화면에서 캐릭터와 발판이 어디에 있는가?
```

2) Temporal Attention

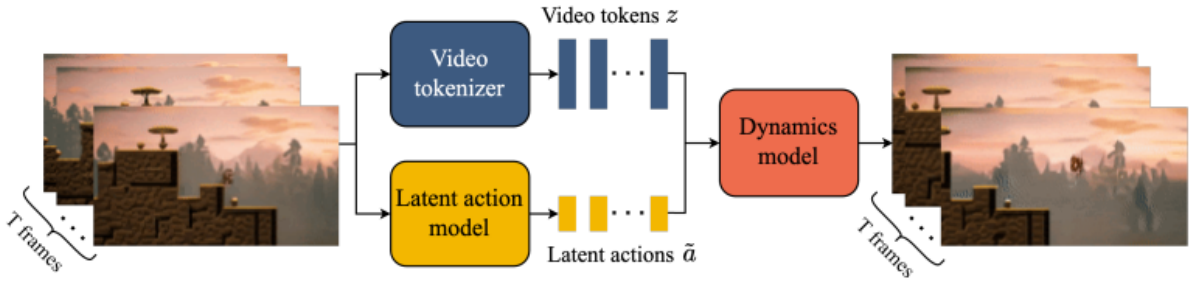
같은 공간 위치가 여러 시간대에 어떻게 변했는지를 봄.

```
이 위치가 frame 1 → frame 2 → frame 3에서 어떻게 변했는가?
```

즉 공간 Attention → 시간 Attention → Feed Forward 구조를 반복

기존 Transformer는 영상 길이가 늘어날수록 계산 비용이 매우 크게 증가하지만, Genie의 ST-Transformer는 주요 계산량이 **프레임 수에 대해 선형적으로 증가하도록 설계**되어 긴 영상 처리를 상대적으로 효율적으로 할 수 있음.

2.1. Model Components



Latent Action Model

영상만 보고 프레임 A에서 프레임 B로 바뀔 때 어떤 행동이 있었을지 추론하는 모델

예를 들어 영상이

```
frame 1: 캐릭터가 중앙
frame 2: 캐릭터가 오른쪽
```

이라면 모델이 이를 보고

```
latent action = A
```

라고 지정할 수 있음.

또

```
frame 1: 캐릭터가 바닥
frame 2: 캐릭터가 공중
```

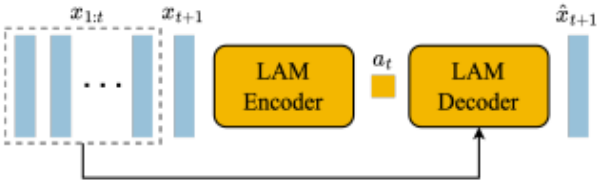
이라면

```
latent action = B
```

처럼 다른 행동을 학습할 수 있음.

중요한 점은 연구자가 A = 오른쪽, B = 점프라고 알려준 적이 없고 모델이 영상 변화 패턴을 보고 자동으로 행동 종류를 만들어냄.

LAM의 학습 과정



LAM에는 Encoder와 Decoder가 존재함.

- Encoder: 이전 프레임들 x_1:t + 다음 프레임 x_(t+1) 을 입력받고 두 프레임 사이의 변화를 설명할 수 있는 잠재 행동을 생성함.

  ⇒ `x_{1:t} = (x_1, \ldots, x_t)`에서 다음 프레임 `x_{t+1}`까지 보고 $\tilde{a}_{1:t} = (\tilde{a}_1, \ldots, \tilde{a}_t)$ 을 추론

- Decoder: 과거 프레임 + latent action만 이용해서 다음 프레임을 재구성

  즉 Decoder 입장에서는 정답 미래 화면을 볼 수 없음.

따라서 미래 프레임을 잘 맞히기 위해서는 latent action이 **현재와 미래 사이의 중요한 변화 정보**를 담고 있어야 함.

왜 행동을 8개로 제한했나?



Genie는 VQ-VAE 방식을 이용해 latent action을 연속적인 값이 아니라 **작은 개수의 이산 코드**로 만듦.

플랫폼 게임 실험에서는 `|A| = 8`로 설정 (= 행동 후보가 최대 8개)

왜 굳이 제한하냐면 행동 종류가 수백 개라면 사람이 직접 조작하기 어려워지기 때문임. 예를 들어 컨트롤러에 버튼이 500개 있다면 게임을 하기 힘든 것과 비슷함.

행동 수를 작게 제한함으로써 action 0, action 1 ... action 7정도의 단순한 컨트롤 인터페이스를 얻음.

실험에서는 일부 행동이 실제로

```
left
right
jump
no-op
```

같은 의미를 자연스럽게 가지게 됨.

VQ-VAE가 여기서 하는 역할

VQ-VAE의 핵심은 연속적인 정보를 **정해진 코드 중 하나로 변환하는 것**임.

예를 들어 모델이 내부적으로 [0.81, -0.22, 0.37, ...]같은 행동 벡터를 만들더라도

가장 가까운 코드가 3번이라면 `latent action = 3`으로 바꾸는 식임.

따라서 행동이 명확하게 구분된 이산 값이 됨.

학습이 끝난 뒤 LAM은 어떻게 됨?

LAM 전체가 실제 플레이 때 계속 사용되는 것은 아님.

학습 중에는 영상 → LAM → 행동 추론을 통해 행동을 알아냄.

하지만 추론 시점에는 사용자가 직접 행동을 입력하기 때문에, **VQ codebook을 제외한 LAM 대부분은 버려짐.**

```
학습할 때
영상 → 행동 발견

실제로 사용할 때
사용자 → 행동 선택
```

Video Tokenizer

원본 영상을 그대로 Transformer에 넣으면 데이터가 너무 큼.

그래서 Video Tokenizer가 영상을 작은 **이산 토큰(discrete token)**으로 압축함.

입력 영상은 $x_{1:T} = (x_1, x_2, \ldots, x_T) \in \mathbb{R}^{T \times H \times W \times C}$형태

- `T`: 프레임 수
- `H`: 이미지 높이
- `W`: 이미지 너비
- `C`: 색상 채널 수

이를 토크나이저가 $z_{1:T} = (z_1, z_2, \ldots, z_T)$ 형태의 이산 토큰으로 변환함.

쉽게 생각하면 GPT가 문장을 단어 토큰으로 바꾸듯이 영상 → 영상 토큰으로 바꾸는 과정

일반 이미지 tokenizer와 차이

기존 방식 중 일부는 각 프레임을 따로 압축함.

하지만 그렇게 하면

```
앞 프레임에서 이 물체가 어디 있었는가?
```

라는 시간 정보가 약해질 수 있음.

Genie의 tokenizer는 ST-Transformer를 사용해서 **공간 정보와 시간 정보를 함께 고려하며 영상을 압축**함.

따라서 각 시점의 토큰 `z_t`는 단순히 현재 프레임뿐만 아니라 이전 프레임 정보도 포함

Dynamics Model

Dynamics Model은 실제로 **다음 세계를 만들어내는 모델**임.

입력: 이전 video tokens + latent actions

출력: 다음 frame의 video tokens

예를 들어

```
현재 화면 = 캐릭터가 왼쪽
action = 오른쪽
```

이면

```
다음 화면 = 캐릭터가 오른쪽으로 이동한 모습
```

을 예측함.

Dynamics Model은 **decoder-only MaskGIT Transformer**를 사용함.

MaskGIT

일반 autoregressive 모델은

```
token 1
→ token 2
→ token 3
→ token 4
```

처럼 하나씩 순서대로 생성함.

MaskGIT는 일부 토큰을 가려둔 뒤

```
[MASK] [MASK] token [MASK]
```

가려진 부분을 여러 번에 걸쳐 채우는 방식임.

Genie에서는 이를 이용해 다음 프레임의 토큰을 생성함.

Dynamics Model의 학습 손실은 예측한 토큰과 실제 토큰 사이의 **Cross Entropy Loss** 임.

학습할 때는 일부 입력 토큰도 무작위로 마스킹하며, 마스킹 비율은 0.5에서 1 사이에서 무작위로 선택함.

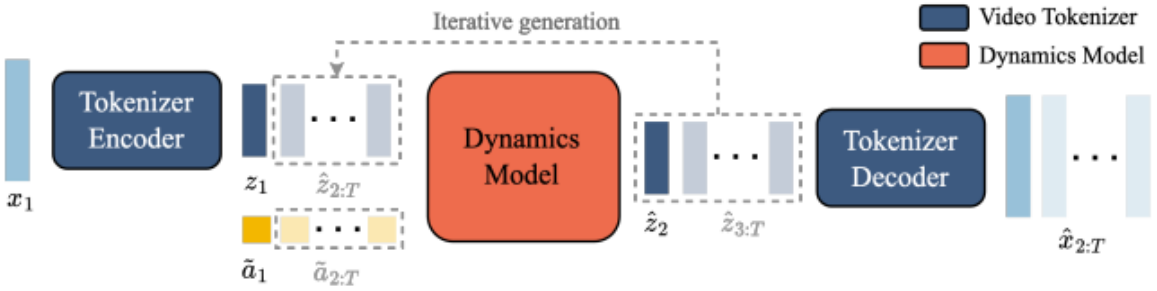
행동 정보를 어떻게 넣나?

보통 World Model에서는 frame token + action token을 단순히 이어붙이는 방식도 사용함.

하지만 Genie 연구진은 행동을 **additive embedding** 형태로 영상 표현에 더해주는 것이 controllability를 더 높였다고 보고함.

즉 행동을 별도 문장처럼 붙이는 것보다 영상 표현 + 행동 표현처럼 직접 결합하는 방식이 더 효과적

2.2. Inference: Action-Controllable Video Generation



학습이 끝나면 실제로 Genie를 어떻게 사용하는지에 대한 부분

처음에는 이미지 `x_1` 하나를 입력함.

예:

```
손으로 그린 게임 그림
실제 사진
AI가 생성한 이미지
```

이 이미지를 Video Tokenizer에 넣어서 `z_1`이라는 영상 토큰으로 변환함.

그 다음 사용자가 행동을 선택함. → $a_1 \in [0, |A|)$

플랫폼 게임에서는 행동이 8개이므로 0 ~ 7 중 하나를 선택하는 것

Dynamics Model은z_1 + a_1을 이용해서 `z_2`를 생성함.

다시 다음 행동 `a_2`를 넣으면 z_1, z_2 + a_1, a_2를 보고 `z_3`를 생성함.

이걸 반복

```
시작 이미지
↓
action 1
↓
frame 2
↓
action 2
↓
frame 3
↓
action 3
↓
frame 4
...
```

즉 사용자의 행동에 따라 계속 다음 프레임이 생성되면서 **게임처럼 조작 가능한 영상**이 만들어짐.

처음에는 action 0이 무엇을 의미하는지 사용자가 모름

하지만 논문에서는 같은 latent action이 여러 환경에서 비교적 일관된 의미를 가지는 것을 관찰함.

---

3. Experimental Results

Genie가 실제로 영상만 학습하고도 조작 가능한 환경을 만들 수 있는지, 그리고 이러한 구조가 모델 규모나 다른 데이터에서도 잘 작동하는지를 확인

Dataset & Metrics

주요 학습 데이터는 인터넷에서 수집한 2D 플랫폼 게임 영상

- 최종 데이터: 약 680만 개의 16초 영상, 총 30,000시간
- 추가로 로봇 영상 데이터에서도 같은 방법을 적용해 일반화 가능성을 확인함
- 로봇 데이터에 포함된 실제 행동 정보는 사용하지 않고 영상만 이용함

평가:

- **FVD ↓**: 생성 영상의 품질 평가. 낮을수록 좋음
- **ΔtPSNR ↑**: latent action이 영상 변화에 실제로 얼마나 영향을 주는지 평가. 높을수록 조작 가능성이 높음

$$\Delta_t PSNR = PSNR(x_t, \hat{x}_t) - PSNR(x_t, \hat{x}'_t)$$

3.1. Scaling Results

모델 크기와 batch size를 키웠을 때 성능이 어떻게 변하는지 확인함.

결과:

- Dynamics Model을 41M → 2.7B까지 키울수록 training loss가 지속적으로 감소함
- batch size를 키웠을 때도 성능이 개선됨
- 즉 Genie 역시 규모를 키울수록 성능이 좋아지는 scaling 특성을 보임

이를 바탕으로 최종 Genie는 약 11B parameter 규모로 학습함.

3.2. Qualitative Results

Platformers-trained model

2D 게임 영상으로 학습한 Genie에 학습 때 보지 못한 형태의 이미지를 입력함.

- 텍스트-이미지 생성 모델의 이미지
- 손으로 그린 그림
- 실제 사진

그럼에도 이미지 속 대상을 움직이며 게임처럼 조작 가능한 영상을 생성함.

또한 앞쪽 물체는 많이 움직이고 배경은 적게 움직이는 Parallax 현상도 자연스럽게 생성함.

즉 단순히 학습 영상을 복사하는 것이 아니라 영상에서 움직임과 장면 변화의 패턴을 어느 정도 학습한 것으로 볼 수 있음.

Robotics-trained model

로봇 영상으로 학습한 모델에서도 행동 라벨을 사용하지 않았지만 latent action이

- 위
- 아래
- 왼쪽

등의 **일관된 행동 의미**를 가지는 모습을 보임.

또 로봇 팔뿐 아니라 로봇이 만지는 물체의 움직임과 변형도 생성함.

→ Genie의 latent action 학습 방식이 **게임에만 한정되지 않음**을 보여줌.

3.3. Training Agents

Genie가 학습한 latent action을 이용해 행동 라벨이 없는 영상에서도 agent를 학습할 수 있는지 실험함.

과정:

```
Expert 영상
↓
LAM이 latent action 추론
↓
현재 화면에서 latent action을 예측하는 policy 학습
↓
소량의 실제 action 데이터로
latent action → 실제 action 연결
```

CoinRun 환경에서 실험한 결과, 약 200개의 실제 action label만 사용해도 실제 expert action으로 직접 학습한 Behavioral Cloning 모델과 비슷한 성능을 보임.

→ 인터넷 영상에서 학습한 latent action이 새로운 환경의 agent 학습에도 활용될 가능성을 보여줌.

3.4. Ablation Studies

Genie의 주요 설계 선택이 실제로 필요한지 비교함.

Latent Action Model 입력

LAM에 압축된 video token을 넣는 방식과 원본 pixel을 직접 넣는 방식을 비교함.

결과:

- 원본 pixel을 사용한 Genie가 전반적으로 더 높은 controllability를 보임
- 영상 압축 과정에서 움직임과 관련된 정보가 일부 손실될 가능성이 있음

→ LAM은 원본 영상을 직접 보는 것이 더 적절함.

Tokenizer 구조

ViT, C-ViViT, Genie의 ST-ViViT을 비교함.

결과:

- ST-ViViT가 가장 좋은 FVD와 ΔtPSNR을 기록함
- 공간과 시간 정보를 모두 고려하면서도 메모리 사용량이 지나치게 크지 않음

→ Genie에서 사용한 ST-ViViT 구조가 영상 품질과 조작 가능성 모두에서 가장 효과적

4. Related Work

World Models

기존 World Model은 현재 상태 + action → 다음 상태를 예측함.

이를 이용하면 실제 환경과 계속 상호작용하지 않고도 내부 모델에서 agent를 훈련할 수 있음.

하지만 기존 방식 대부분은 World Model 자체를 학습할 때 action-labeled data가 필요함.

GAIA-1이나 UniSim 같은 최근 대형 World Model 역시 텍스트나 행동 라벨을 사용함.

Genie의 차이점은 공개된 video-only data로 world model을 학습한다는 것

Video Models

기존 영상 생성 모델은 보통 텍스트 또는 초기 frame → 나머지 영상 생성 방식

Genie 역시 MaskGIT과 ST-Transformer를 이용한다는 점에서 이런 모델들과 관련이 있음.

하지만 Genie의 목적은 단순 영상 생성이 아니라

```
latent action
↓
영상의 진행 방향을 사용자가 결정
```

하게 만드는 것

즉 agent가 직접 조작할 수 있는 영상 모델을 목표로 함

Playable Video Generation

기존 Playable Video Generation도 영상에서 latent action을 찾아 조작 가능한 영상을 생성하려는 접근임.

하지만 기존 연구는 주로 특정 환경에 특화된 예제를 다룸.

Genie는 이를 훨씬 큰 데이터와 범용 구조로 확장해서

```
처음 보는 이미지
↓
새로운 플레이 가능한 환경
```

을 만드는 것을 목표로 함

Environment generation

기존 Procedural Content Generation은 알고리즘이나 머신러닝을 이용해 게임 맵과 레벨을 생성함.

최근에는 언어 모델이 게임 코드를 직접 생성하는 방법도 존재함.

Genie는 코드나 명시적인 게임 규칙을 만드는 대신 픽셀 영상에서 직접 세계의 시각적 변화와 행동 패턴을 학습함.

Training agents with latent actions

기존에도 latent action을 이용한 imitation learning, planning, RL pretraining 연구가 존재함.

VPT의 경우 인터넷 영상에 action을 붙이기 위해 사람이 제공한 action-labeled data로 inverse dynamics model을 먼저 학습함.

반면 Genie는 action-labeled data 없이 인터넷 영상 자체에서 latent action 학습

---

5. Conclusion and Future Work

Genie의 핵심 아이디어는 단순히 영상을 생성하는 AI가 아니라, 사용자가 실제로 들어가서 조작할 수 있는 세계를 생성하는 AI

이를 위해 기존 World Model처럼 action-labeled data를 요구하지 않고

```
Internet Video
↓
영상 변화 관찰
↓
latent action 발견
↓
action-controllable world model 학습
```

이라는 방법을 제안함.

한계

1. 미래 hallucination

Autoregressive 모델이므로 시간이 지나면서 현실적이지 않은 장면을 생성할 수 있음.

= 초반에는 자연스럽다가 여러 프레임을 반복 생성하면 세계 구조가 이상하게 변할 수 있음.

2. 짧은 memory

현재 모델은 **16 frames**의 정보만 사용함. 10 FPS 기준이면 약 1.6초 정도의 직접적인 영상 문맥임.

따라서 장시간 동안 동일한 세계 구조를 유지하기 어려움. 예를 들어 멀리 갔다가 다시 돌아왔을 때 예전 장소를 정확히 기억하는 문제 등이 발생할 수 있음.

3. 느린 생성 속도

현재 Genie는 약 1 FPS 수준으로 동작함.

실제 게임은 일반적으로 훨씬 높은 FPS가 필요하기 때문에 실시간 인터랙션용으로는 아직 매우 느림.

Future Work

연구진은 앞으로 더 많은 인터넷 영상을 활용하면 게임, 로봇, 현실 환경, 상상의 환경 등 다양한 세계를 학습하는 **Foundation World Model**로 발전할 가능성을 제시함.

특히 강화학습에서 가장 큰 문제 중 하나가 다양하고 풍부한 훈련 환경을 만드는 것이 어렵다는 점인데 Genie가 이런 환경 자체를 생성해줄 수 있다면 generalist agent 학습에 활용할 수 있음

Broader Impact

Societal Impact

논문에서는 Genie가 사람들이 자신의 게임형 환경을 쉽게 만들 수 있는 도구가 될 가능성을 언급함.

예를 들어 어린이가 직접 그림을 그리고

```
그림
↓
Genie
```

```
↓
직접 움직여볼 수 있는 세계
```

로 만들 수 있음.

따라서 게임 제작이나 창작 활동의 진입장벽을 낮출 가능성이 있음. genie

Training Data and Weights

다만 연구진은 현재

```
훈련된 checkpoint
훈련 데이터셋
훈련 데이터 예시
```

를 공개하지 않음.

안전하고 책임 있는 공개 방법을 연구 커뮤니티와 게임 커뮤니티와 논의할 필요가 있다고 설명함. genie

Reproducibility

11B Genie 전체를 그대로 재현하기에는 계산 비용이 매우 큼.

그래서 논문 Appendix에서는 **중간급 GPU 또는 TPU 하나로 약 일주일 안에 학습 가능한 작은 CoinRun 버전**을 따로 제공함.

즉 전체 Genie는 재현하기 어렵지만 핵심 구조와 학습 방식 자체는 작은 규모에서 실험할 수 있도록 설계함.