week 8 - DeepSeek

1. Abstract

LLM, CoT, 프롬프팅 → 인간이 **직접 작성한 예시 데이터에 크게 의존**하고 있음
→ 더 복잡한 문제에 대해서는 모델의 능력이 여전히 부족

> ⭐ **순수한 RL을 통해 인간이 라벨링한 추론 과정 無**
> → LLM 추론 능력 향상

2. Introduction

- 사전 학습 단계에서 추론 능력, emergent 행동 生 과정
  → 상당한 컴퓨팅 자원 요구
- CoT 프롬프팅 - 최소한의 프롬프트 사용

  → 인간이 직접 작성한 추론 trace(흔적)에 의존
  → 확장성 저해 + 제공한 예시 수준의 성능에 갇힘
  (인간과는 다른 더 우수한 추론 경로 탐색 가능성 차단)

> 💡인간의 라벨링 작업에 대한 의존을 **최소화**
> + 강화학습(RL) 프레임워크 내에서의 **자기 진화(self-evolution)**
> → **LLM의 추론 능력을 개발할 수 있는 잠재력 탐구**

▼ 세부 내용

- DeepSeek-V3-Base(DeepSeek-AI, 2024b)를 기반으로 하여 Group Relative Policy Optimization(GRPO)(Shao et al., 2024)을 RL 프레임워크로 사용
- 보상 신호는 추론 과정 자체에 어떠한 제약도 부과하지 않은 채, 오직 최종 예측이 정답과 일치하는지 여부에만 기반
- RL 훈련 이전의 일반적인 지도 미세조정(SFT) 단계를 생략

→ 인간이 정의한 추론 패턴이 모델의 탐색을 제한
+ 제약 없는 RL 훈련은 LLM에서 새로운 추론 능력이 발현되도록 더 잘 유도할 수 있음

3. Related work - DeepSeek-R1-Zero

2.1. Group Relative Policy Optimization

(대규모 RL의 효율성을 높이기 위해 채택)

- Proximal Policy Optimization(PPO)의 훈련 과정 → 단순화, 자원 소모 줄이기 위해 제안
- 각 질문 q에 대해, GRPO는 이전 정책 πθold로부터 출력의 그룹 {o1, o2, · · · , oG}를 샘플링한 후, 다음 목적 함수를 최대화함으로써 정책 모델 πθ를 최적화

2.2. 보상 설계

- 규칙 기반 보상을 사용
  - 정확도 보상(accuracy rewards)
    - 응답이 정확한지 평가
    - 최정 답을 지정된 형식으로 제공하도록 요구
      → 정확성에 대한 신뢰할 수 있는 규칙 기반 검증 O (객관적인 피드백 生)
  - 형식 보상(format rewards)
    - 특정 형식 요건 강제 → 정확도 보상 모델 보완

      ▼ 자세한 내용

      지정된 태그, 즉 '<think>'와 '</think>' 안에 담도록 유도

→ 모델의 사고 과정이 명시적으로 구분되도록 보장하여 해석 가능성을 높이고 이후의 분석을 용이하게 함

- 정확도 보상과 형식 보상은 동일한 가중치로 결합
- 한계
  - 재훈련에 상당한 컴퓨팅 자원 필요
  - 훈련 파이프라인에 추가적인 복잡성 초래 → 전체 최적화 과정 복잡함
  - 가독성 저하,언어 혼용

자기 진화(self-evolution)
모델에게 문제를 푸는 방법을 명시적으로 가르치는 대신,
단지 올바른 인센티브만을 제공함으로써 모델이 스스로 정교한 문제 해결 전략을 발전시킴

기존 연구 대비 차이점

- SFT 없이 오직 RL에만 의존 (기존 연구)

4. Method

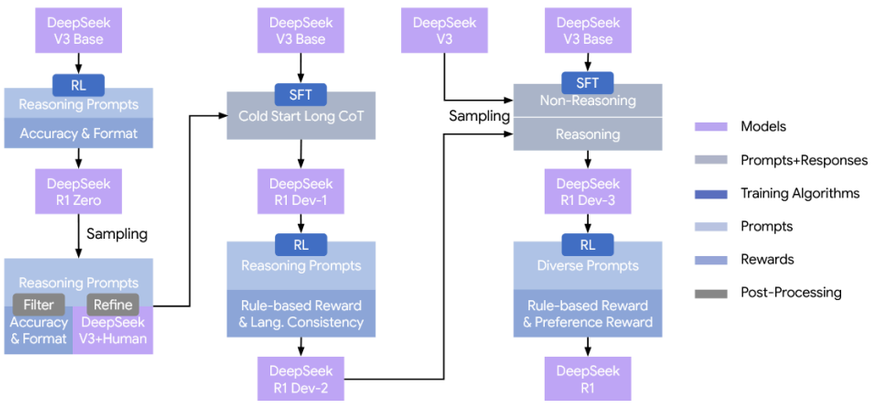


Figure 2 | The multi-stage pipeline of DeepSeek-R1. A detailed background on DeepSeek-V3 Base and DeepSeek-V3 is provided in Supplementary A.1. The models DeepSeek-R1 Dev1, Dev2, and Dev3 represent intermediate checkpoints within this pipeline.

초기 단계 → **대화체**

1. 인간과 정렬된 사고 과정을 보여주는 수천 개의 콜드스타트 데이터 수집
2. RL 훈련 적용
   → 대화체 사고 과정과 언어 일관성 측면에서 모델 성능 향상 시킴
3. 거부 샘플링과 SFT 한 번 더 적용
   → 추론 + 고급 글쓰기 능력도 발휘할 수 있도록

⭐ 2차 RL 단계 적용

모델의 유용성, 무해성 향상 + 추론 능력 정교화

단계	대응되는 훈련 과정	주요 특징
DeepSeek-R1-Zero	순수 RL만 적용 (SFT 없음)	추론 능력은 뛰어나지만 가독성 낮고 언어 혼용
Dev1	콜드스타트 데이터로 SFT + 1차 RL	지시사항 이행 능력(IF-Eval, ArenaHard) 향상, 다만 콜드스타트 데이터 양이 적어 AIME 등 추론 성능은 R1-Zero보다 일부 저하
Dev2	(Dev1 이후) 추론 중심 RL 추가 적용	코드, 수학, STEM 등 고급 추론 벤치마크에서 뚜렷한 향상. 범용 과제(AlpacaEval 등)는 미미한 개선
Dev3	거부 샘플링 + 추론/비추론 데이터를 함께 사용한 SFT	비추론 말뭉치·코드 엔지니어링 데이터 포함으로 AlpacaEval 2.0, Aider-Polyglot 등 범용/실용 과제에서 성능 향상
DeepSeek-R1 (최종)	Dev3에 추론+범용 혼합 데이터로 2차 (종합) RL 적용	코드·수학은 이미 앞 단계에서 최적화되어 소폭 개선에 그침. 대신 일반 지시 이행·사용자 선호 벤치마크가 크게 향상 (AlpacaEval 2.0 +25%, ArenaHard +17%)

3. Experiments

	Benchmark (Metric)	R1-Zero	R1-Dev1	R1-Dev2	R1-Dev3	R1
English	MMLU (EM)	88.8	89.1	**91.2**	91.0	90.8
	MMLU-Redux (EM)	85.6	90.0	93.0	93.1	92.9
	MMLU-Pro (EM)	68.9	74.1	83.8	83.1	**84.0**
	DROP (3-shot F1)	89.1	89.8	91.1	88.7	**92.2**
	IF-Eval (Prompt Strict)	46.6	71.7	72.0	78.1	**83.3**
	GPQA Diamond (Pass@1)	**75.8**	66.1	70.7	71.2	71.5
	SimpleQA (Correct)	30.3	17.8	28.2	24.9	30.1
	FRAMES (Acc.)	82.3	78.5	81.8	81.9	**82.5**
	AlpacaEval2.0 (LC-winrate)	24.7	50.1	55.8	62.1	**87.6**
	ArenaHard (GPT-4-1106)	53.6	77.0	73.2	75.6	**92.3**
Code	LiveCodeBench (Pass@1-COT)	50.0	57.5	63.5	64.6	**65.9**
	Codeforces (Percentile)	80.4	84.5	90.5	92.1	**96.3**
	Codeforces (Rating)	1444	1534	1687	1746	**2029**
	SWE Verified (Resolved)	43.2	39.6	44.6	45.6	**49.2**
	Aider-Polyglot (Acc.)	12.2	6.7	25.6	44.8	**53.3**
Math	AIME 2024 (Pass@1)	77.9	59.0	74.0	78.1	**79.8**
	MATH-500 (Pass@1)	95.9	94.2	95.9	95.4	**97.3**
	CNMO 2024 (Pass@1)	**88.1**	58.0	73.9	77.3	78.8
Chinese	CLUEWSC (EM)	93.1	92.8	92.6	91.6	92.8
	C-Eval (EM)	**92.8**	85.7	91.9	86.4	91.8
	C-SimpleQA (Correct)	66.4	58.8	64.2	66.9	63.7

Table 3 | Experimental results at each stage of DeepSeek-R1. Numbers in bold denote the performance is statistically significant (t−test with $p < 0.01$).

- DeepSeek-R1 Dev3은 추론 및 비추론 데이터셋을 모두 SFT 파이프라인에 통합함으로써, 추론 과제와 일반적인 언어 생성 과제 모두에서 모델의 숙련도를 향상
- Dev2와 비교했을 때, DeepSeek-R1 Dev3은 대규모 비추론 말뭉치와 코드 엔지니어링 데이터셋의 포함에 힘입어 AlpacaEval 2.0과 Aider-Polyglot에서 눈에 띄는 성능 향상을 달성

4. Conclusion

1. 한계점

- **구조화된 출력 및 도구 사용**
  - 구조화된 출력 능력은 기존 모델들에 비해 여전히 최적화되어 있지 않음
  - DeepSeek-R1은 검색 엔진이나 계산기와 같은 도구를 활용하여 출력 성능 향상 X
- **토큰 효율성**
  - 당면한 문제의 복잡성에 따라 추론 시 컴퓨팅 자원을 동적으로 할당
    → 더 단순한 질문에 대해서도 과도한 추론(overthinking)으로 나타나는 현상이 여전히 관찰
- **언어 혼용**
- **보상 해킹**
  - 특정 과제에서는 신뢰할 수 있는 RM을 구축하기 어려움

2. 결론

- **사전학습된 체크포인트가 본질적으로 복잡한 추론 과제에 대한 상당한 잠재력을 이미 보유하고 있음을 보임**
- 복잡한 추론 과제 성능향상 핵심은 대규모 인간 주석 작업 X
  → 어려운 추론 문제, 신뢰할 수 있는 검증기(verifier), 그리고 강화학습을 위한 충분한 컴퓨팅 자원을 제공하는 데 있음