week 8 - GPT

1. Abstract

- 레이블링된 데이터 부족 → 판별적 학습
  - 학습된 모델이 충분한 성능을 내기 어려움

    ⭐ **이러한 경우에서도 충분한 성능 향상을 낼 수 있도록 함** (해결점)

비레이블 텍스트 코퍼스 (핵심 아이디어)
→ 언어 모델의 생성적 사전 학습 먼저 수행
→ 각 특정 과제에 대해 판별적 fine-tuning

2. Introduction

- **비레이블 텍스트로부터 단어 수준을 넘어선 정보 활용 어려움**
  - transfer에 유용한 텍스트 표현 학습에 어떤 최적화 목적 함수가 가장 효과적인지 불분명
  - 학습된 표현을 목표 과제로 전이하는 가장 효과적인 방법에 대한 합의 無

💡**비지도 사전학습과 지도 미세조정을 결합한, 언어 이해 과제를 위한 준지도 접근법 탐구**

- **연구 목표**
  - 광범위한 과제들에 대해 거의 fine-tuning 없이 전이될 수 있는 범용적인 표현을 학습하는 것

▼ 메소드 간략 설명

1. 레이블이 없는 데이터에 대해 언어 모델링 목적함수를 사용하여 신경망 모델의 초기 파라미터를 학습
2. 이 파라미터들을 해당하는 지도 목적함수를 사용하여 목표 과제에 맞게 적응시킴

3. Related work

Semi-supervised learning for NLP

- 비레이블 데이터 사용 → 단어, 구, 문장 수준의 통계 계산을 지도학습 모델의 특징으로 사용
- 임베딩을 다양한 목표 과제에 적합한 벡터 표현으로 인코딩 하는데 사용

Unsupervised pre-training

- semi-supervised learning의 특수한 경우
- 지도학습의 목적함수 수정 대신, 좋은 초기화 지점을 찾는 것을 목표로 함

기존 연구 대비 차이점

- 단어 수준을 넘어 상위 수준의 의미 포착
  - **traversal-style 입력 변환**만으로 구조화된 입력(문장 쌍, 문서-질문-답변 등)을 하나의 연속된 토큰 시퀀스로 바꿔 처리
- 최소한의 아키텍처 변경으로 광범위한 과제에 적용함
- 비지도 사전학습 단계 자체만으로 이미 다운스트림 과제에 유용한 언어학적 지식을 상당 부분 학습 (보조 목적함수 사용 없이)

4. Method

대규모 텍스트 코퍼스 고용량 언어 모델 학습 → 레이블이 있는 데이터 사용하여 판별적 fine-tuning

1. 비지도 사전학습

$$L_1(U) = \Sigma_i logP(u_i|u_{i-k}, ..., u_{i-1}; \Theta)$$

- 조건부 확률 P : 파라미터 Θ를 갖는 신경망을 통해 모델링
  - 파라미터들은 SGD를 통해 학습
- 다층 트랜스포머 디코더 사용(트랜스포머 변형)

  입력 문맥 토큰들에 대해 멀티헤드 셀프 어텐션(multi-headed self-attention) 연산을 적용
  → 위치별 피드포워드 계층(position-wise feedforward layers)을 거쳐 목표 토큰들에 대한 출력 분포 生

(파라미터들을 지도학습 목표 과제에 맞게 적응)

2. 지도 fine-tuning

$P(y|x_1, ..., x_m) = softmax(h_l^m W y)$ - (3)

(3) 식을 통해 아래 목적 함수 최대화

$$L2(C) = \Sigma_(x, y) log P(y|x_1, ..., x_m)$$

- 언어 모델링을 fine-tuning에 보조 목적함수로 포함
  - 지도 학습 모델의 일반화 성능 향상
  - 수렴 가속화 → 학습에 도움

$$L3(C) = L2(C) + \lambda * L1(C)$$

3. 과제별 입력 변환

질의응답, 텍스트 함의(textual entailment)
→ 순서가 있는 문장 쌍이나, 문서·질문·답변의 삼중항(triplet)과 같은 구조화된 입력

순회(traversal) 방식 접근법

→ 순서화된 시퀀스로 변환

- 과제 전반에 걸쳐 아키텍처 대폭 변경 피할 수 있음

3. Experiments

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	89.3	-	-	-
CAFE [58] (5x)	80.2	79.0	89.3	-	-	-
Stochastic Answer Network [35] (3x)	80.6	80.1	-	-	-	-
CAFE [58]	78.7	77.9	88.5	83.3		
GenSen [64]	71.4	71.3	-	-	82.3	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	**61.7**
Finetuned Transformer LM (ours)	**82.1**	**81.4**	**89.9**	**88.3**	**88.1**	56.0

Table 2: Experimental results on natural language inference tasks, comparing our model with current state-of-the-art methods. 5x indicates an ensemble of 5 models. All datasets use accuracy as the evaluation metric.

- **LSTM이 제로샷 성능에서 더 큰 분산(variance)을 보임**

  → 트랜스포머 아키텍처의 귀납적 편향(inductive bias)이 전이를 돕는다는 것을 시사
- **사전학습의 부재**
  - 모든 과제에 걸쳐 성능을 저하시켜, 전체 모델 대비 14.8%의 성능 하락을 초래한다는 것을 관찰

4. Conclusion

1. 한계점

- **디코더 전용 트랜스 포머**
  - 문맥을 조건화 함
    (각 토큰 예측 시, 이전 토큰들만 참조 가능 → 이후 BERT(양방향 사전 학습) 등장)
- **소규모 데이터셋에서 사전 학습의 이점이 일관되게 나타나지 않음**
  - RTE(2,490개 비교적 작은 데이터셋)에서 멀티태스크 biLSTM 모델(61.7%)보다 낮은 56%의 정확도를 보임

2. 결론

- **생성적 사전학습과 판별적 미세조정을 통해 단일한 과제 비특화(task-agnostic) 모델 제안**
  - 긴 연속 텍스트 구간 포함한 다양한 코퍼스에 대한 사전학습 진행

    → **world knowledge, 장거리 의존성 처리 능력 有**
    (질의응답, 의미 유사도 평가, 함의 판단, 텍스트 분류 → 판별적 과제 해결 O)
- 우리가 연구한 12개 데이터셋 중 **9개에서 SOTA 달성**
- **비지도 사전 학습을 통해 → 판별적 과제에서 성능 향상이 목표**
  → 이를 입증함