week 9 -RAG

arxiv.org

https://arxiv.org/pdf/2005.11401

1. Abstract

- 모델 판단 근거 제시, 세계 지식 갱신 여전히 해결되지 않은 과제로 남음

  → 💡**사전 학습된 파라미터적 메모리 + 비파라미터적 메모리 언어 生**

2. Introduction

- 사전학습된 신경망 언어 모델은 깊이 있는 지식 학습 O

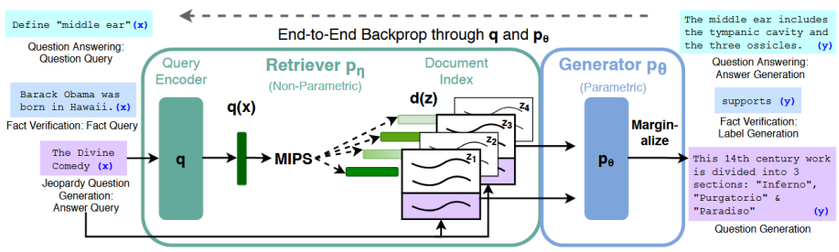
  하지만, 쉽게 메모리 확장/수정 X + 환각(Hallucination) 生

- 하이브리드 모델 (파라미터적 + 비파라미터적 메모리)
  - 직접 지식 수정, 확장 O
  - 지식 검사, 해석 O

  ➖ 오픈 도메인 추출형 질의응답만을 탐구

NLP의 주력 모델인 seq2seq모델에 하이브리드 방식을 적용

→ 사전학습된 접근 메커니즘 사용함으로써, 추가적인 학습 없이도 지식에 접근하는 능력 有



▼ 간략한 figure 설명

RAG

- 파라미터적 메모리 : 사전학습된 seq2seq 트랜스포머
  비파라미터적 메모리 : 위키피디아의 밀집 벡터 인덱스
- 구성 요소 → 종단간(end-to-end)으로 학습되는 확률 모델로 결합
- 검색기(Dense Passage Retriever, DPR)
  : 입력에 조건화된 잠재 문서(latent document) 제공
- seq2seq 모델
  : 잠재 문서들과 입력에 함께 조건을 걸어 출력을 생성

** 파인 튜닝 O, generator, retriever가 함께 공동으로 학습됨

3. Related work

메모리 네트워크, 스택 증강 네트워크, 메모리 레이어

- 특정 태스크를 위해 처음부터(from scratch) 학습
- 비파라미터적 메모리로 시스템 강화

→ 생성기가 검색된 텍스트에 직접 조건화/ TF-IDF를 통해 얻어짐(end-to-end 방식 X)

Retrieve-and-Edit 접근법

- 주어진 입력에 대해 유사한 학습용 입력-출력 쌍을 검색
  → 이를 편집하여 최종 출력 제공
  - 의미 분석, 기계 번역 등 여러 분야에서 성공적이었음을 입증함

- 본 연구와 차이점
  - 검색된 여러 내용의 조각 → 내용 종합
    (검색된 항목을 가볍게 편집 X)
  - 잠재 검색 학습 → 근거가 되는 문서 검색

4. Method

> 💡 **전반적인 과정**
> 입력 시퀀스 `x` 사용
> → 텍스트 문서 `z` 검색, 목표 시퀀스 `y` 생성 시 추가적인 맥락으로 사용

- 검색기(retriever), 생성기(generator)로 구성
- 생성된 텍스트에 대한 분포 생성을 위해
  - RAG-Sequence
    : 모델이 동일한 문서를 사용하여 각 목표 토큰 예측
  - RAG-Token
    : 서로 다른 문서에 기반하여 목표 토큰 예측
- generator와 retriever를 동시에 학습(어떤 문서가 검색되어야 하는지에 대한 직접적인 감도 無)
- 디코딩 ($argmax\ p(y|x)$ 근사)은 따로
  - RAG-Sequence는 $p(y|x)$가 기존의 토큰 단위 우도로 분해 X
    → 단일 빔 서치로 풀 수 X
  - **Thorough Decoding**

3. Experiments

	Model	NQ	TQA	WQ	CT
Closed Book	T5-11B [52]	34.5	- /50.1	37.4	-
	T5-11B+SSM[52]	36.6	- /60.5	44.7	-
Open Book	REALM [20]	40.4	- / -	40.7	46.8
	DPR [26]	41.5	**57.9/** -	41.1	50.6
	RAG-Token	44.1	55.2/66.1	**45.5**	50.0
	RAG-Seq.	**44.5**	56.8/**68.0**	45.2	**52.2**

Table 1: Open-Domain QA Test Scores.

- REALM, T5+SSM처럼 비용이 큰 특수 사전학습(salient span masking) 없이도 이 성능을 냈다

Model	Jeopardy B-1	Jeopardy QB-1	MSMARCO R-L	MSMARCO B-1	FVR3 Label	FVR2 Acc.
SotA	-	-	**49.8***	**49.9***	**76.8**	**92.2***
BART	15.1	19.7	38.2	41.6	64.0	81.1
RAG-Tok.	**17.3**	**22.2**	40.1	41.5	72.5	89.5
RAG-Seq.	14.7	21.4	40.8	44.2		

- 정답 문단(gold passage) 없이도 정답 문단을 활용하는 SOTA 모델에 근접
  → 검색-생성 결합의 효율성을 보여줌

	Factuality	Specificity
BART better	7.1%	16.8%
RAG better	**42.7%**	**37.4%**
Both good	11.7%	11.8%
Both poor	17.7%	6.9%
No majority	20.8%	20.1%

Table 4: Human assessments for the Jeopardy Question Generation Task.

- RAG가 BART보다 사실적이라는 응답 42.7% (vs 7.1%)로 압도적

4. Conclusion

1. 한계점

- Retriever, generator의 완전한 공동 학습 부재
  - DPR, BART(genrator)를 결합해 파인튜닝만 한 구조
  - 학습 중에도 문서 인코도(BERRd) 고정
    쿼리 인코더, genrator만 파인튜닝

    → 검색 표현 자체가 다운스트림 태스크에 완전히 최적화 X
    (절반의 end-to-end 학습)
- 검색 방식이 모든 태스크에 최적은 아님
  - FEVER 실험
    → 학습된 밀집 검색(dense retrieval)이 단순한 BM25보다 오히려 성능 ↓
  - 성능이 외부 지식 소스(위키피디아)의 범위에 제한

2. 결론

- 파라미터적 메모리와 비파라미터적 메모리가 어떻게 상호작용하는지, 효과적인 결합 방법에 대한 연구 방향을 제시함