week 10 Diffusion

arxiv.org
https://arxiv.org/pdf/2006.11239

1. Abstract

> **고품질 이미지 합성(high-quality image synthesis)을 어떻게 안정적이고 효과적으로 수행할 것인가**라는 문제 다룸

2. Introduction

연구 동기 (Motivation)

1. **디퓨전 모델의 이론적 장점**
   - 디퓨전 모델은 **정의가 단순하고 학습이 효율적**이라는 매력적인 특성을 가짐
   - 데이터에 점진적으로 노이즈를 추가하는 과정(디퓨전 과정)을 역으로 학습하는 구조로, 수학적으로 다루기 쉬움
   - 노이즈가 가우시안이면 샘플링 체인도 조건부 가우시안으로 단순하게 파라미터화 O

문제점 (Problem / Research Gap)

1. **미해결 핵심 질문: 고품질 샘플 생성이 가능한가?**
   - 디퓨전 모델은 이론적으로 간단하고 학습도 쉽지만,
     "실제로 고품질 이미지를 생성할 수 있는지"는 그때까지 입증된 바가 없었음
   - 즉, GAN처럼 시각적으로 뛰어난 샘플을 만들어낼 수 있는 실증적 증거가 부재했던 것이 연구 공백(gap)
2. **모델 학습 목적함수와 이론적 근거의 불명확성**
   - 디퓨전 모델을 어떻게 파라미터화하고 어떤 손실 함수로 학습해야 최선의 성능이 나오는지에 대한 이해가 부족
3. **우도(likelihood) 성능의 한계**
   - 디퓨전 모델이 좋은 샘플을 만들더라도, 다른 우도 기반 모델 대비 로그 우도 자체는 경쟁력이 떨어질 가능성이 있음
   - 특히 무손실 코드 길이의 대부분이 지각 불가능한(imperceptible) 이미지 디테일을 표현하는 데 낭비되는 비효율성이 존재

3. Method

디퓨전 모델의 역방향 과정 평균(μ_θ)을 직접 예측하는 대신,
각 단계에서 더해진 노이즈 ε를 예측하는 신경망(ε_θ)으로 재파라미터화함

1. 구조 설계

- **순방향 과정**
  : 분산 β_t는 학습하지 않고 상수로 고정 → 설계 단순화
- **역방향 과정**
  - 분산 $\sigma_t^2 I$도 학습하지 않고 고정
  - 평균은 $\varepsilon_\theta(x_t, t)$로부터 역산 $(x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1-\bar{\alpha}_t)}\varepsilon)$

2. 이 재파라미터화의 효과

- 목적함수가 **디노이징 스코어 매칭**과 유사한 형태로 단순화
- 샘플링 과정이 **랑주뱅 동역학**과 유사한 구조를 가짐

3. 알고리즘

- **학습**: t, ε를 무작위로 뽑아 $\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2$ 를 최소화하는 회귀 문제
- **샘플링**: x_T $N(0, I)$에서 시작해, ε_θ로 노이즈를 반복적으로 제거하며 x_0까지 역추적

4. 목적함수 단순화

- 원래 변분 하한의 가중치를 제거(unweighted)한 형태 사용
  → 노이즈가 적은 쉬운 구간(작은 t)의 비중을 낮추고, 어려운 구간(큰 t)의 디노이징에 학습 집중
  → 실험적으로 샘플 품질 향상

4. Experiments

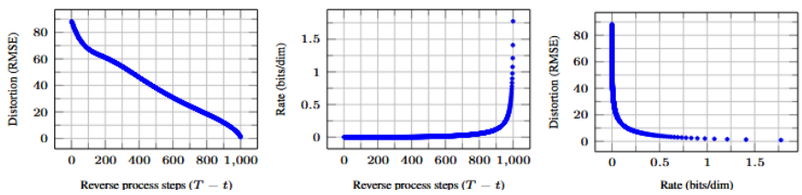


Figure 5: Unconditional CIFAR10 test set rate-distortion vs. time. Distortion is measured in root mean squared error on a [0, 255] scale.

그래프	내용
왼쪽	역방향 스텝(T−t) vs Distortion — 진행될수록 **선형적으로 꾸준히 감소**
가운데	역방향 스텝(T−t) vs Rate — 대부분 구간에서 정체, **후반부(800~1000)에 급증**
오른쪽	Rate vs Distortion — **낮은 rate에서 distortion 급감**, 이후 완만

5. Conclusion

1. 한계점

1. **우도(log-likelihood) 성능 부족**
   - 샘플 품질은 뛰어나지만, 다른 우도 기반 생성 모델에 비해 로그 우도/코드길이 자체는 경쟁력이 없으며, 코드길이의 절반 이상이 지각 불가능한 디테일 표현에 낭비됨
2. **느린 샘플링 속도**
   - T=1000 스텝을 거치는 순차적 역방향 과정이 필요
     → 한 번의 forward pass로 샘플링하는 GAN 등에 비해 샘플링 속도가 현저히 느림

2. 결론

디퓨전 모델은 서로 다른 개념(변분 추론·디노이징 스코어 매칭·랑주뱅 동역학·자기회귀 모델·손실 압축)들을 이론적으로 통합하면서도,
실제로 GAN에 필적하는 **고품질 이미지를 생성**할 수 있음을 최초로 입증함