week 10 GAN

arxiv.org
https://arxiv.org/pdf/2006.11239

1. Abstract

> **복잡한 확률적 추론 없이, 두 신경망의 게임만으로 데이터 분포를 학습하는 방법**

Adversarial Net

: 생성 모델은 적대자와 맞서게 됨.
이 적대자는 어떤 샘플이 모델 분포에서 나온 것인지 실제 데이터 분포에서 나온 것인지를 판별

2. Introduction

🚔 **D(판별자)** : 위조지폐를 적발하려는 경찰

💰 **G(생성자)** : 위조지폐를 만들어 들키지 않고 사용하려는 위조범 팀

기존 생성 모델의 한계

- 기존의 생성 모델들은 학습 과정에서
  마르코프 체인(Markov chain)을 사용하거나, **근사 추론(approximate inference)을 위한 언롤링된(unrolled) 네트워크**가 필요했음

  → **계산 비용 大, 학습 과정 복잡**

💡 **G(생성자)와 D(판별자) 두 모델의 경쟁(adversarial process)**
→ 간접적으로 **데이터 분포를 학습**하는 방식 제안

👍 **역전파만으로 전체 시스템 학습 가능 + 계산적으로 훨씬 간단하고 효율적**

3. Related work

RBM/DBM 계열

- 분배함수(partition function)가 다루기 힘들어 MCMC로 추정해야 하고, 믹싱 문제가 발목을 잡음

DBN

- 방향성·비방향성 모델의 어려움을 둘 다 떠안는 하이브리드

스코어 매칭/NCE

- 확률 밀도를 정규화 상수까지 해석적으로 명시해야 하는 제약

GSN 등

- 마르코프 체인의 파라미터를 학습하는 방식
  — GAN과 목적은 비슷하지만 여전히 **마르코프 체인이 필요함**

4. Method

1. Adversarial nets

기본 구성

- **생성자 G**
  - 입력 노이즈 `z ~ p_z(z)` 를 받아 데이터 공간으로 매핑하는 다층 퍼셉트론 `G(z; θg)`
- **판별자 D**

- 입력 `x`가 실제 데이터일 확률(스칼라 값)을 출력하는 다층 퍼셉트론 `D(x; θd)`

학습 목표

- **D** : 실제 데이터와 G가 생성한 가짜 데이터에 올바른 레이블을 매길 확률을 **최대화**
- **G** : D가 자신이 만든 가짜를 진짜로 착각하게, 즉 `log(1 − D(G(z)))` 를 **최소화**

미니맥스 게임 ⭐

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}(x)}[\log D(x)] + \mathbb{E}_{z\sim p_z(z)}[\log(1-D(G(z)))]$$

- D와 G가 하나의 가치함수 `V(D,G)`를 두고 서로 반대 방향으로 경쟁하는 2인 게임
- 이론적으로 G, D에 충분한 표현력(용량)이 주어지면 이 게임의 해는 **G가 실제 데이터 분포를 정확히 복원**하는 지점

5. Experiments

실험 설정

항목	내용
데이터셋	MNIST, Toronto Face Database (TFD), CIFAR-10
생성자(G) 활성화 함수	ReLU + sigmoid 혼합
판별자(D) 활성화 함수	maxout
판별자 학습 기법	dropout 적용
노이즈 입력 위치	이론상 중간층에도 넣을 수 있지만, **실제로는 최하단 입력층에만** 노이즈 투입

평가 방법: Gaussian Parzen Window 추정

- **문제**
  → GAN은 명시적인 확률 밀도 함수가 없어서 우도(likelihood)를 직접 계산할 수 없음
- **해결책**
  → G가 생성한 샘플들에 가우시안 파젠 창을 씌워서 근사 분포를 만들고, 그 분포 하에서 테스트 데이터의 로그우도를 추정
- **σ(가우시안 폭) 결정 :** 검증 세트에서 교차 검증으로 튜닝

결과

Model	MNIST	TFD
DBN [3]	138 ± 2	1909 ± 66
Stacked CAE [3]	121 ± 1.6	$\mathbf{2110 \pm 50}$
Deep GSN [6]	214 ± 1.1	1890 ± 29
Adversarial nets	$\mathbf{225 \pm 2}$	$\mathbf{2057 \pm 26}$

Table 1: Parzen window-based log-likelihood estimates.

- 다른 생성 모델(DBN, Stacked CAE 등)과 비교했을 때 MNIST에서는 경쟁력 있는 수치 보임
- TFD에서는 다소 밀리거나 비슷한 수치

6. Conclusion

1. 한계점

- **명시적 확률 밀도 없음**
  - `p_g(x)` 를 직접적인 수식으로 표현할 수 없음 (오직 샘플링만 가능)
- **G와 D의 동기화 필요**
  - G를 D 업데이트 없이 너무 많이 학습시키면 **"헬베티카 시나리오(Helvetica scenario)"** 발생 위험 有

▼ Helvetica scenario

생성자(Generator)가 서로 다른 입력 잠재 벡터(z)들을 동일한 하나의 출력(x)으로 매핑해 버리는 현상

→ 실제 데이터의 **다양성을 반영하지 못하는** 현상

2. 결론

- **적대적 모델링 프레임워크의 실현 가능성을 입증**