week 11 CLIP

💡 기존 컴퓨터 비전 시스템 → 미리 정해진 고정된 카테고리 집합만 예측하도록 학습
(새로운 시각적 개념 다루려면 매번 추가적인 레이블링 데이터를 生)
→ 일반성, 확장성 ↓
해결
→ 자연어(텍스트)를 지도 신호로 사용

- 별도의 데이터셋별 학습 無 → 다양한 시각 과제에 제로샷으로 전이 가능한 이미지 표현 학습 (CLIP 모델 핵심)

1. Abstract

- 최신 컴퓨터 비전 시스템
  : 미리 정해진 고정된 물체 범주 집합 예측 (제한된 형태의 지도학습)

  → 새로운 시각적 개념 지정을 위해 추가 레이블링 데이터 필요
  → 일반성, 활용성 한계

💡 이미지에 대한 원시 텍스트 직접 학습
→ 광범위한 지도 학습 자원 활용 O
인터넷에서 수집한 4억 개의 데이터 쌍에서
→ 캡션 - 이미지 쌍 예측 (단순한 과제) 학습

- **효율적, 확장 O**

2. Introduction

연구 동기

- NLP에서의 성공 사례
  - GPT-3
    : **원시 텍스트로부터 직접 학습** (사전학습 방식) → 혁신
    : 별도의 데이터셋 맞춤화 없이도, 다양한 과제에 제로샷으로 전이 O
- **컴퓨터 비전은 아직 뒤처져 있음**
  - ImageNet 같은 크라우드 레이블링 데이터셋에 의존하는 것이 표준 관행
  - **"웹 텍스트로부터 직접 학습하는 방식이 비전에서도 비슷한 돌파구가 될 수 있을까?"** → 저자들의 질문
- **선행 연구들의 고무적 결과**
  - Mori(1999), Quattoni(2007), Joulin(2016), Li(2017), VirTex/ICMLM/ConVIRT(2020)
    → 텍스트 기반 이미지 표현 학습의 가능성을 보여줌

기존 접근법의 문제점

- **자연어 지도 학습 기반 모델(Li et al., 2017) ImageNet 제로샷 정확도 11.5%에 불과**
  → 당시 SOTA(88.4%)는 물론 고전적 비전 기법(50%)에도 못 미침
- **약한 지도 학습(weak supervision)의 한계**
  - 클래스 수를 1,000개/18,291개로 **인위적으로 제한**
    → 자연어의 표현력을 온전히 활용하지 못함
  - **정적인 소프트맥스 분류기**를 사용
    → 동적 출력이 불가능해 유연성과 제로샷 능력이 제한됨
- **규모(scale)의 격차**
  - 약한 지도 학습 모델들은 수백만~수십억 이미지로 가속기-연(年) 단위 학습
  - 자연어 기반 모델(VirTex, ICMLM, ConVIRT)은 10만~20만 이미지로 가속기-일(日) 단위 학습
    → **규모 자체가 훨씬 작았음**

> 위 문제(특히 **규모의 격차**)를 해소하기 위해,
> 인터넷에서 수집한 **4억 개의 (이미지, 텍스트) 쌍**으로 대규모 자연어 지도 학습을 수행하는 **CLIP**을 제안
> → 이를 통해 제로샷 전이 성능과 확장성을 검증

3. Related work

자연어를 지도 신호로 쓰는 연구 (가장 넓은 범주)

- 토픽 모델, 워드/문장 벡터, 언어 모델 등 **분포 의미론(distributional semantics)** 전체를 아우르는 매우 광범위한 흐름
- **대화 기반 학습**: 대화 속 피드백으로부터 학습(Weston 2016 등)
- **설명(explanation) 활용**: 자연어 설명을 특징이나 레이블로 변환(Srivastava 2017, Hancock 2018), ExpBERT(2020)처럼 관계 추출에 자연어 설명을 조건으로 활용

  → CLIP은 이 중에서도 **"언어가 아닌 다른 도메인(비전)을 학습하는 데 자연어를 신호로 쓰는"** 사례에 해당

대규모 이미지-텍스트 데이터셋 구축 흐름 — WIT의 위치

- 기존 크라우드소싱 데이터셋(Pascal1K, Flickr8K/30K)은 **품질은 좋지만 규모가 작음**
- 자동 구축 데이터셋들(Conceptual Captions, LAIT, OCR-CC 등)이 등장했지만, **여전히 100만~1,000만 개 수준**으로 CLIP의 WIT(4억 개)보다 훨씬 작음

  → WIT는 규모 면에서 이 흐름의 **연장선이자 큰 도약**

웹 지도 학습(Webly Supervised Learning) — 가장 유사한 개념

- 검색 엔진에 단어를 검색해서 **그 검색어 자체를 레이블로 사용**하는 방식(Fergus 2005)
- **CLIP과의 차이점**:
  - 웹 지도 학습: 검색어(보통 단어 1개~짧은 n-그램) 자체를 레이블로 사용
  - CLIP: 이미지와 **함께 등장하는 텍스트 전체 문장**을 지도 신호로 사용
  - 웹 지도 학습: 복잡한 이미지 검색엔진(내부에 CV 시스템 포함)에 의존
  - CLIP: 단순한 **부분 문자열 일치 검색**만 사용

비전-언어 결합 모델(Vision-Language Joint Models) — 최근 가장 활발한 경쟁 흐름

- BERT류 언어모델 + 이미지 특징 모델 + 영역 제안/물체 탐지 모델,
  3개 이상의 사전학습된 서브시스템을 결합한 복잡한 아키텍처(Lu 2019, Tan & Bansal 2019 등)
- VQA, 시각적 상식 추론 등 **복잡한 멀티모달 다운스트림 과제**에 특화되어 인상적 성과를 냄
- **CLIP과의 결정적 차이**:
  - 이 흐름: 이미지-텍스트를 **촘촘한 결합 어텐션**으로 깊게 연결
  - CLIP: 이미지·텍스트 도메인 간 상호작용이 **임베딩 공간에서의 단 한 번의 내적(dot product)뿐**
    → 훨씬 단순하고 처음부터(from scratch) 학습 가능

4. Method

1. 자연어 지도 학습

⭐ **자연어(훈련 신호)에 담긴 지도 신호로부터 지각(perception)을 학습**

▼ 초기 연구

토픽 모델
: 대량의 문서 집합에서 숨겨진 추상적인 주제를 찾아내는 통계적 및 자연어 처리(NLP) 기법

n-그램 표현
: 주어진 텍스트에서 연속된 **N개의 항목(단어, 음절, 문자 등)**을 잘라내어 통계적 분석이나 예측에 사용하는 자연어 처리(NLP)의 기본 단위
(분석을 위해 텍스트를 분해하는 단위)

▼ 크라우드 소싱 레이블링 절차

: ImageNet 같은 데이터셋을 만들 때 쓰인 방식

1. **고정된 카테고리 집합 정의**
   - 연구자가 미리 “고양이”, “개” 등 예측하고자 하는 클래스 목록을 정함
2. **작업자에게 이미지 배포**
   - 다수의 작업자에게 이미지를 보여주고, 미리 정해진 카테고리 중 어느 것에 해당하는지 고르게 함
3. **1-of-N 다수결 방식**
   - 여러 작업자가 같은 이미지 라벨을 매기고,
     가장 많은 표를 받은 카테고리를 정답 레이블(gold label)로 확정

     → canonical 1-of-N majority vote ‘gold label’방식
4. **검수/필터링**
   - 애매하거나 합의가 안 되는 이미지는 제외하거나 추가 검수 거침

👎 **한계**

- 각 이미지가 **N개 중 정확히 하나의 클래스**에만 속하도록 강제

  → 이미지가 가질 수 있는 풍부하고 미묘한 의미를 담지 못함
- 새로운 카테고리를 추가하려면 처음부터 다시 사람을 시켜 레이블링 해야 함

  → 확장성 ↓
- 대규모로 하려면 막대한 인건비, 시간 필요 (ImageNet도 완성까지 수년 걸림)

이를 하는 이유

- 자연어를 다루는 방법들은 **인터넷상의 방대한 텍스트**에 담긴 지도 신호로부터 수동적으로 학습 O
- 단순히 표현만 학습하는 것이 아니라 그 **표현을 언어와 연결**시켜 유연한 제로샷 전이 O

2. 데이터셋 구축

WIT(WebImageText)

- 자체 제작 데이터셋
- 인터넷상의 다양한 공개 출처로부터 수집한 4억 개의 (이미지, 텍스트) 쌍으로 이루어짐
- 50만 개의 쿼리 집합 중 텍스트에 포함된 (이미지, 텍스트) 쌍을 검색

  → 가능한 한 폭넓은 시각적 개념을 포괄하기 위해
  - 쿼리당 최대 2만 개의 (이미지, 텍스트) 쌍만 포함시켜 결과의 클래스 균형을 대략적으로 맞춤

    (쿼리 : “고양이”, “강아지” ...)

3. 효율적인 사전 학습 방법 선택

최신 컴퓨터 비전 시스템들은 엄청난 양의 연산 자원 사용

→ **학습 효율성**이 자연어 지도 학습을 성공적으로 확장하는데 핵심

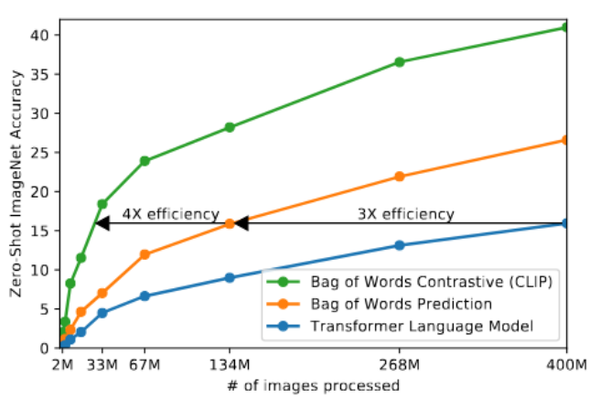


Figure 2. CLIP is much more efficient at zero-shot transfer than our image caption baseline.

▼ Figure 2 설명

- 6,300만 개 파라미터의 트랜스포머 언어 모델
  - 동일한 텍스트의 bag-of-words 인코딩 예측 보다 ImageNet 인식을 3배 느리게 학습
    (단순한 베이스라인)
- 예측 목적 함수를 **CLIP의 대조(contrastive) 목적 함수로 바꾸자 효율성이 추가로 4배 더 향상됨**

▼ 선형 투영 vs 비선형 투영

CLIP은 이미지 인코더(CNN/ViT)와 텍스트 인코더(Transformer)를 통과시켜 각각 "표현(representation)" 벡터를 얻는다.

근데, 이 두 표현은 서로 다른 공간에 있어서(차원도 다르고 성질도 다름) 바로 비교할 수 X

→ 같은 공간(멀티모달 임베딩 공간)으로 옮겨주는(=투영하는) 과정이 필요

선형 투영(linear projection)	그냥 행렬 곱셈 한 번으로 벡터를 다른 차원으로 옮기는 것. 수식으로 치면 `y = Wx` 형태. 아주 단순한 "직선적인" 변환
비선형 투영 (nonlinear projection)	행렬 곱셈 뒤에 ReLU 같은 비선형 활성화 함수를 끼워 넣고, 보통 층을 여러 개 쌓은 작은 신경망(MLP)을 통과시키는 것. 예: `y = W2 * ReLU(W1x)`. → 더 복잡하고 유연한 변환.

- 텍스트의 정확한 단어가 아니라,
  어떤 텍스트 전체가 어떤 이미지와 짝지어지는지만 예측하도록 학습 (proxy task-대리과제)
- N개의 (이미지, 텍스트) 쌍으로 이루어진 배치 주어지면,
  - CLIP은 배치 내에서 NxN 개의 (이미지, 텍스트) 조합 중 **실제로 존재하는 조합이 무엇인지 예측**하도록 학습
- 이미지 인코더 + 텍스트 인코더 함께 학습 → 멀티 모달 임베딩 공간 학습
  - 배치 내 실제 존재하는 N개 쌍의 (이미지, 텍스트) 임베딩 코사인 유사도 **최대화**
  - 잘못된 $N^2 - N$개 조합의 임베딩 간 코사인 유사도는 **최소화**

  → 대칭적인 교차 엔트로피 손실 최적화
- **과적합은 큰 우려 사항 X**
  - 사전 학습 데이터셋의 규모가 매우 크기 때문에
- 이미지 인코더를 ImageNet 가중치로, 텍스트 인코더를 사전 학습된 가중치로 초기화하지 않고 **CLIP을 처음부터 학습**
- **인코더의 표현을 멀티모달 임베딩 공간으로 매핑하는 데 선형 투영만을 사용**
  - 표현과 대조 임베딩 공간 사이에 비선형 투영을 사용 X

  ▼ 표현 공간/대조 임베딩

  1. 표현(representation) 공간

  - 이미지 인코더(ResNet/ViT)나 텍스트 인코더(Transformer)가 입력을 통과시켜 내놓는 **원래의 출력 벡터**가 있는 공간이야.
  - 이 벡터는 그 인코더가 "이 이미지/텍스트를 이해한 내용"을 담고 있는 숫자 뭉치(벡터)인데, 이미지 인코더가 뱉는 벡터와 텍스트 인코더가 뱉는 벡터는 **차원 수도 다르고 성질(스케일, 분포)도 서로 완전히 다름**.
  - 비유하자면, 한쪽은 "한국어로 쓴 메모", 다른 쪽은 "영어로 쓴 메모" 같은 거야. 둘 다 의미는 담고 있지만 서로 바로 비교할 수 있는 형태가 아니야.

  2. 대조 임베딩(contrastive embedding) 공간 = 멀티모달 임베딩 공간

  - 이미지 표현과 텍스트 표현을 **같은 차원, 같은 좌표계**로 옮겨놓은 공유 공간이야.
  - 이 공간으로 옮겨야만 "이 이미지 벡터와 이 텍스트 벡터가 얼마나 가까운지(코사인 유사도)"를 계산할 수 있어. CLIP의 학습 목표 자체가 "짝이 맞는 이미지-텍스트는 이 공간에서 가깝게, 안 맞는 건 멀게" 만드는 거니까 이 공유 공간이 반드시 필요함.

- 비유하면, 한국어 메모와 영어 메모를 각각 "공통 언어(예: 숫자 좌표)"로 번역해서 같은 지도 위에 점으로 찍는 거야. 그래야 두 점 사이 거리를 잴 수 있으니까.

- 선형/비선형 투영 사이의 학습 효율성 차이 찾지 못함.

다양한 파라미터 설정

1. 텍스트 변환 함수 tu 제거

▼ Zhang et al.(2020)

- Zhang et al.(2020)의 원래 방법에서는,
  이미지 하나에 텍스트(설명)가 여러 문장 달려있을 때 그중 **한 문장을 무작위로 골라서** 사용하는 전처리 단계(tu)가 있음.
  (예: "의료 영상 리포트"처럼 한 이미지에 여러 문장짜리 설명이 달린 경우)

- CLIP이 쓰는 데이터셋(인터넷에서 긁어온 이미지+텍스트)은
  애초에 **텍스트가 짧은 한 문장짜리인 경우가 多**
- "여러 문장 중 하나를 고르는" 이 단계 자체가 필요 X.
  → 그래서 그냥 이 과정을 삭제.

2. 이미지 변환 함수 tv 단순화

- 이미지 쪽 전처리(데이터 증강)도 복잡하게 하지 않고, **딱 한 가지만** 사용
- 이미지를 적당한 크기로 리사이즈한 다음, 그중에서 **정사각형 영역을 무작위 위치에서 잘라내는 것(random crop)** 뿐.

  ▼ 이유

  - 보통 이미지 학습에서는 색상 왜곡, 회전, 좌우반전 등 다양한 증강 기법을 겹겹이 쓰는데, CLIP은 이런 걸 다 빼고 최소한으로만 했음.
    (데이터가 워낙 방대해서 굳이 복잡한 증강이 필요 없었던 것으로 보임.)

3. 온도 파라미터 τ를 직접 학습시킴

▼ 배경

- 배경: CLIP은 이미지-텍스트 유사도 점수(로짓)를 계산한 뒤, 소프트맥스에 넣어서 "어느 쌍이 진짜 짝인지" 확률로 바꿈.
  이때 **온도(temperature) τ**라는 값이 이 점수들의 "날카로움 정도"를 조절해. (τ가 작으면 점수 차이가 극단적으로 벌어지고, 크면 완만해짐.)
- 보통은 이 τ 값을 사람이 직접 이것저것 시도해보며(하이퍼파라미터 튜닝) 최적값을 찾아야 하는데, CLIP은 이 수고를 덜기 위해 **τ 자체를 학습 가능한 파라미터로 만들어서, 모델이 학습 과정에서 스스로 최적값을 찾아가도록** 했어.

- 로그 파라미터화된 곱셈 스칼라
  - τ를 직접 학습시키지 않고 **log(τ)를 학습**시킨 뒤 나중에 지수함수(exp)를 취해서 사용.

  → τ 값이 항상 **양수로 유지되고 학습이 더 안정적**

> **불필요한 전처리 단계들을 다 빼버렸고**,
> 사람이 일일이 조정해야 했던 온도 파라미터까지 **모델이 스스로 학습하도록** 만들어서 전체적으로 구현을 훨씬 단순하게 유지

4. 모델 선택 및 스케일링

- **이미지 인코더**
  - ResNet-50
    - 인코더의 기본
    - 널리 채택되고, 검증된 성능 有

      ▼ 추가 개선 사항

      - **ResNetD 사용**

        - 원래 ResNet에는 다운샘플링(feature map 크기를 줄이는) 과정에서 정보를 일부 손실하는 작은 비효율 有
        - 이런 세부적인 구조를 몇 군데 손봐서(예: 다운샘플링 시 컨볼루션 배치 방식 변경 등) **정보 손실을 줄이고 성능을 조금 더 끌어올린** 개선판
    - 안티앨리어싱 블러 풀링 (Zhang, 2019)
        - 다운샘플링 직전에 **살짝 블러(흐림) 처리**를 해줘서 변화에 더 안정적으로(robust) 만드는 기법
        - CNN에서 이미지 크기를 줄이는 풀링(다운샘플링)을 할 때, 그냥 확 줄여버리면 이미지에 약간의 변화(예: 몇 픽셀 이동)만 있어도 결과가 크게 달라지는 불안정한 현상 生
          (즉, 모델이 "사진이 1픽셀 옆으로 이동해도 똑같은 물체로 인식"하게 도와주는 안정화 기법.)
    - **전역 평균 풀링 → 어텐션 풀링으로 교체**
        - 전역 평균 풀링
          CNN이 만든 마지막 특징 맵(feature map, 여러 위치의 정보가 담긴 그리드)을 그냥 **모든 위치의 값을 단순 평균**내서 하나의 벡터로 뭉개버리는 방식.
          → 이미지의 "어느 부분이 더 중요한지"는 고려하지 않고 다 똑같이 취급
        - **어텐션 풀링** ⭐
            - **트랜스포머의 어텐션 메커니즘**을 한 층 사용해서 "이미지의 어느 부분에 더 집중해야 할지"를 학습을 통해 알아서 결정하게
            - 여기서 "쿼리(query)"는 먼저 전역 평균 풀링으로 얻은 대략적인 이미지 요약 벡터를 사용하고,
            - 이 쿼리가 "키(key)/값(value)" 역할을 하는 원래 특징 맵의 각 위치들을 보면서, "이 이미지를 대표하려면 어느 위치의 정보가 더 중요한지" 가중치를 매겨서 종합함.
  - Vision Transformer(ViT)
    - 원 구현 거의 그대로 따름
    - 트랜스포머 이전에 결합된 패치 미치 임베딩에 추가적인 레이어 정규화 추가
    - 초기화 방식 약간 수정
  - 튜닝
    - 너비, 깊이, 해상도 증가에 추가 연산을 동일하게 배분하는 단순한 기준 방식을 사용
- **텍스트 인코더**
  - 6,300만 개 파라미터, 12층, 512폭, 8개의 어텐션 헤드를 가진 모델을 사용 (기본 크기)
  - 트랜스포머는 어휘 크기 49,152의 소문자 바이트 페어 인코딩(BPE) 텍스트 표현(Sennrich et al., 2015)에서 작동
    - 최대 시퀀스 길이는 76으로 제한 (계산 효율성을 위해)
  - [EOS] 토큰에서의 트랜스포머 최상위 층 활성값을 텍스트의 특징 표현으로 취급
    - 모든 토큰 정보를 다 참고할 수 있어서
    - 이 벡터를 뽑은 다음
      → **레이어 정규화**(값의 스케일을 안정적으로 맞춰줌)
      → **선형 투영**(공유 임베딩 공간에 옮기는 것)을 거쳐서 **최종 텍스트 임베딩 生**
  - Masked Self attetion 사용
    - 각 위치의 토큰이 **자기보다 앞에 있는 토큰들만** 볼 수 있고, 뒤에 오는 토큰은 못 보게 막아놓은 방식
      (GPT 같은 언어 생성 모델이 사용하는 방식)

    ▼ (CLIP은 텍스트-이미지 짝만 맞히는 과제라 양방향 어텐션이 더 유리할 수 있지만, masked 사용 이유)

    - 나중에 GPT 같은 **이미 사전 학습된 언어 모델의 가중치로 텍스트 인코더를 초기화**하고 싶을 수도 있는데,
      → 그러려면 구조(마스크드 방식)가 똑같아야 호환이 됨.
    - 나중에 CLIP의 대조 학습 목표 외에,
      "다음 단어 맞히기" 같은 언어 모델링 과제를 보조 목표로 추가하고 싶을 수도 있는데,
      → 마스크드 구조여야 가능함(미래 단어를 미리 보면 "맞히는" 의미가 없어지니까).

→ 향후 과제로 남김

- 튜닝
  - ResNet의 너비 증가 비율에 맞춰 모델의 너비만 확장하고 깊이는 전혀 확장하지 X
    → CLIP의 성능이 텍스트 인코더의 용량에 상대적으로 덜 민감하다는 것을 발견했기 때문

5. 학습

- **학습시킨 모델 구성**

계열	모델	비고
ResNet (5개)	ResNet-50, ResNet-101	기본 모델
	RN50×4, RN50×16, RN50×64	EfficientNet 스타일 스케일링, ResNet-50 대비 각각 약 **4배·16배·64배** 연산량
Vision Transformer (3개)	ViT-B/32, ViT-B/16, ViT-L/14	—

- **공통 학습 설정**
  - **에폭 수** : 모든 모델 **32 에폭**
  - **옵티마이저** : Adam + **분리된 가중치 감쇠(decoupled weight decay)** (gain·bias 제외 모든 가중치에 적용)
  - **학습률 스케줄** : **코사인 스케줄**로 감쇠
  - **미니배치 크기** : **32,768** (매우 큼)
- **하이퍼파라미터 튜닝 방식**
  - 초기값: 1 에폭 학습한 **기준 ResNet-50**으로 그리드서치 + 랜덤서치 + 수동 튜닝
  - 더 큰 모델들: 계산 자원 제약으로 **휴리스틱하게 조정**
- **온도 파라미터(τ) 처리**
  - 초깃값: (Wu et al., 2018) 기준 **0.07**
  - 학습 불안정 방지를 위해 **로짓을 100배 이상 확대하지 못하도록 클리핑**
- **메모리·속도 최적화 기법**
  - **혼합 정밀도(mixed-precision)** 학습
  - **그래디언트 체크포인팅**
  - **반정밀도 Adam 통계량**
  - **반정밀도 확률적 반올림** 텍스트 인코더 가중치
  - **임베딩 유사도 계산 샤딩**: 각 GPU가 자기 로컬 배치에 필요한 유사도만 계산

  ▼ 용어 설명

  - **혼합 정밀도(mixed-precision) 학습**
    - 모든 계산을 32비트로 하지 않고, 일부는 16비트(FP16, "반정밀도")로 계산해서 속도를 높이고 메모리를 아끼는 기법.
  - **그래디언트 체크포인팅(gradient checkpointing)**
    - **일부 중간값만 저장**해두고, 나머지는 필요할 때 **다시 계산(재연산)**해서 얻는 방식
    - **메모리 ↔ 연산량 트레이드오프** 기법
  - **확률적 반올림(stochastic rounding)**
    - 값을 반올림할 때 "위로 반올림할지 아래로 반올림할지"를 **확률적으로 결정**해서, 평균적으로는 원래 값에 더 가깝게 유지되도록 하는 방법

- **학습 비용**

모델	GPU	기간
RN50×64 (최대 ResNet)	V100 592개	18일

모델	GPU	기간
최대 ViT	V100 256개	12일

- **최종 대표 모델 (사실상 "CLIP"으로 불리는 모델)**
  - **ViT-L/14**를 기반으로, FixRes 기법처럼 **336픽셀 고해상도**에서 **1 에폭 추가 사전 학습**
  - 이를 **ViT-L/14@336px**로 명명

3. Experiments

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	**98.4**	**76.2**	**58.5**

Table 1. Comparing CLIP to prior zero-shot transfer image classification results.

- ImageNet 제로샷 정확도: 11.5% → **76.2%**
- 128만 개 ImageNet 학습 데이터를 **전혀 쓰지 않고도** 지도학습 ResNet-50과 동급

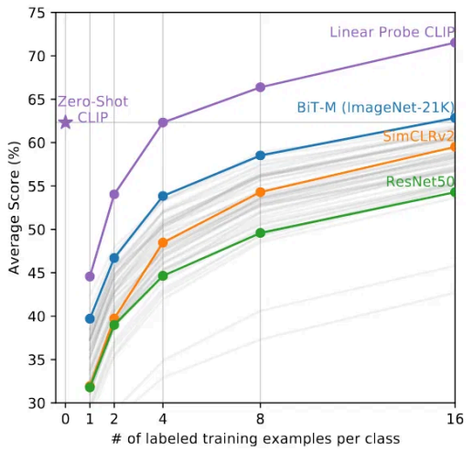


Figure 6. Zero-shot CLIP outperforms few-shot linear probes.

- **예시 개수가 많은 것 = 무조건 좋은 것"이 아니라는 게 포인트**
- 자연어로 "이건 고양이다"라고 직접 알려주는 것이,
  사진 딱 1~2장만 보고 "이 사진에서 뭐가 핵심 개념인지" 알아서 추측하게 하는 것보다
  → 오히려 더 **명확하고 효율적인 정보 전달 방식**이기 때문
  → 사진 한 장에는 배경, 다른 물체 등 여러 정보가 섞여 있어서, 예시가 적을수록 "무엇을 배워야 하는지" 헷갈리기 쉬움.

▼ **zero-shot vs few-shot**

- **Few-shot (1~2장)**: "여기 사진 1~2장을 줄게, 이게 무슨 개념인지 네가 알아서 추론해봐"
  - **N-shot** : 클래스당 사진 N장만 보고 학습
- **Zero-shot**: "이 개념의 이름은 '고양이'야" 하고 **정답을 직접 말로 알려줌**
  - 클래스 **이름(텍스트)만 알려주면** 그 클래스를 인식할 수 있는 능력

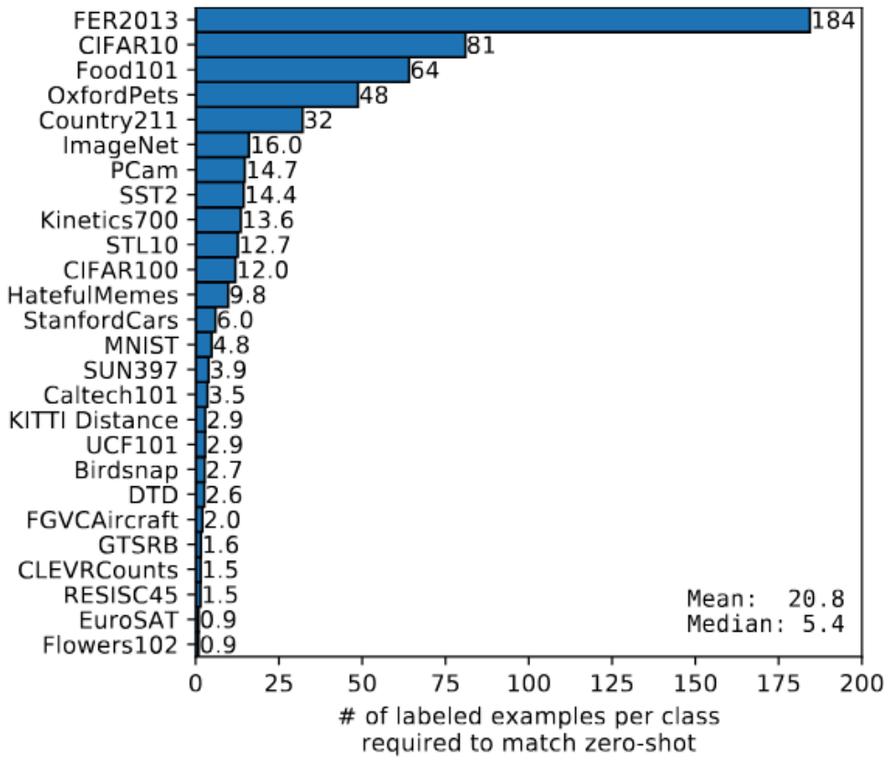


Figure 7. The data efficiency of zero-shot transfer varies widely.

- 제로샷의 "실질적 데이터 가치"를 숫자로 환산

  → 제로샷 CLIP의 성능과 맞먹으려면, 지도학습 모델은 클래스당 레이블 몇 개가 필요한가

  ▼ 그래프 지표 수집 과정

  - 앞서 본 그림 6처럼, 같은 특징(feature) 공간에서 1-shot, 2-shot, 4-shot, ..., 완전지도학습까지 로지스틱 회귀 성능을 측정한 다음
  - "제로샷 CLIP의 정확도"와 정확히 같아지려면 클래스당 레이블이 몇 개 필요한지를 보간(interpolation)해서 추정한 값

- 막대가 길수록
  = **제로샷을 따라잡기 위해 더 많은 레이블이 필요함**
  = 제로샷이 그만큼 "많은 레이블을 대체할 만큼 가치있다"는 뜻.
- 반대로 **Flowers102: 0.9개**, **EuroSAT: 0.9개**

  → 1개도 안 되는 값.

  - 즉, **1-shot 지도학습조차 제로샷보다 나음**
    → 이 두 데이터셋에서는 제로샷이 오히려 약함
    (앞서 그림 5에서 CLIP이 부진했던 데이터셋들과 일치)

  ▼ 제로샷이 약한 데이터셋 특징

  - **일반적인 물체/장면(ImageNet, CIFAR 등)**: 인터넷 텍스트에 "고양이", "자동차" 같은 표현이 흔하게 등장 → 제로샷이 잘 통함
  - **세분화된 전문 분류(Flowers102의 특정 꽃 품종, FGVCAircraft의 특정 기종)**: 일반인이 인터넷에 "이건 ○○종 장미다"라고 정확히 이름 붙여 쓰는 경우가 드뭄 → 제로샷이 약함
  - **추상적/전문적 판단이 필요한가 (비전문가도 못 하는 과제)**
    - **의료 영상(림프절 종양 탐지)**: 사람도 전문 지식 없이는 판단 불가능한 과제 → 제로샷은 물론 사람도 어려움
    - **거리 추정(KITTI Distance), 물체 개수 세기(CLEVRCounts)**: 텍스트로 "이 차까지의 거리는 3m다"처럼 표현하는 경우가 거의 없어서 언어로 배우기 어려운 개념

  일상적으로 사진에 캡션을 달 때 자연스럽게 등장하는 개념(일반 사물, 동작, 장면)일수록 제로샷이 강한

- **하단 요약 통계**

- **중앙값(Median): 5.4** → 절반의 데이터셋에서는 클래스당 약 5~6개의 레이블만 있어도 제로샷과 맞먹을 수 있음
- **평균(Mean): 20.8** → 평균이 중앙값보다 훨씬 높은 이유는, FER2013(184), CIFAR10(81) 같은 **일부 극단적으로 큰 값들이 평균을 끌어올리기 때문**. (분포가 한쪽으로 치우친, 오른쪽 꼬리가 긴 분포)

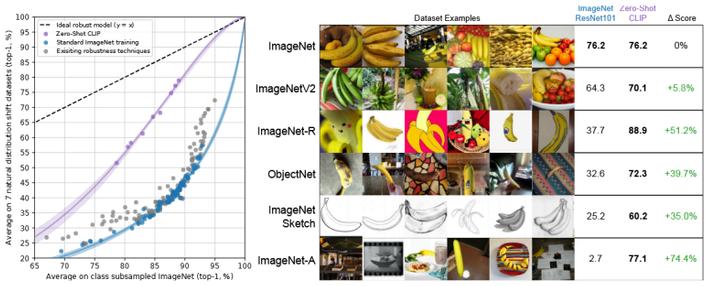


Figure 13. Zero-shot CLIP is much more robust to distribution shift than standard ImageNet models.

▼ 왼쪽 그래프 : 산점도 의미

축이 의미하는 것

- **x축 (가로)**: "class subsampled ImageNet"에서의 정확도. 즉, 원래 ImageNet과 같은 종류의 사진들로 평가했을 때의 성능.
- **y축 (세로)**: 7개의 "자연스러운 분포 변화" 데이터셋(그림/스케치/실제 다른 환경에서 찍힌 사진 등)에서 평가했을 때의 **평균** 성능.

점/선의 의미

- **검은 점선(y = x)**: "이상적으로 견고한 모델" 기준선. 이 선 위에 있다는 건 "평소 학습한 데이터에서 잘하는 만큼, 낯선 환경에서도 똑같이 잘한다"는 뜻.
- **파란 점 (Standard ImageNet training)**: 기존 ImageNet 지도학습 모델들. 검은 점선에서 한참 아래로 처져 있음 → ImageNet에서는 잘하지만, 조금만 환경이 달라지면 성능이 뚝 떨어짐.
- **회색 점 (Existing robustness techniques)**: "견고성을 높이겠다"고 나온 기존 기법들. 파란 점보다는 조금 낫지만 여전히 검은 점선에서 많이 떨어져 있음.
- **보라색 점 (Zero-Shot CLIP)**: CLIP을 제로샷으로 썼을 때. 검은 점선(이상적 모델)에 **훨씬 더 가깝게** 붙어있음 → "환경이 달라져도 성능이 잘 안 떨어진다"는 뜻.

- 산점도(왼)
  - 같은 ImageNet 정확도 수준이라면, 제로샷 CLIP이 다른 환경(분포 변화)에서도 훨씬 더 안정적으로 성능을 유지
- 오른쪽 표: 실제 예시 이미지와 데이터셋별 비교

  ▼ 표 의미

데이터셋	어떤 이미지들인지
ImageNet	원본 형태의 평범한 실사 사진
ImageNetV2	ImageNet과 같은 방식으로 새로 수집한 사진 (재현 테스트용)
ImageNet-R	그림, 낙서, 조각상, 만화 등 **예술적/렌더링된** 형태
ObjectNet	특이한 배경, 각도, 상황에서 찍힌 사진
ImageNet Sketch	손으로 그린 **스케치**
ImageNet-A	모델이 헷갈리기 쉽게 만든 **적대적(어려운)** 사진들

  - 원본 ImageNet에서는 둘 다 **76.2%로 동일** (0% 차이)
    — 공정한 비교 기준점.
  - 그런데 이미지가 조금이라도 "낯선 형태"로 바뀌면:
    - ImageNet-R(그림/렌더링): ResNet101 37.7% vs CLIP 88.9% → **+51.2%**
    - ImageNet Sketch: 25.2% vs 60.2% → **+35.0%**
    - ImageNet-A(어려운 사진): 겨우 2.7% vs 77.1% → **무려 +74.4%**

💡 같은 "바나나"를 알아보는 능력이라도,
ResNet101은 평범한 사진에서만 잘 통하고 그림·스케치·특이한 상황이 되면 거의 못 맞히는 반면,
제로샷 CLIP은 형태가 달라져도 꾸준히 잘 알아본다
— **실질적 견고성(effective robustness)**이 높다는 의미

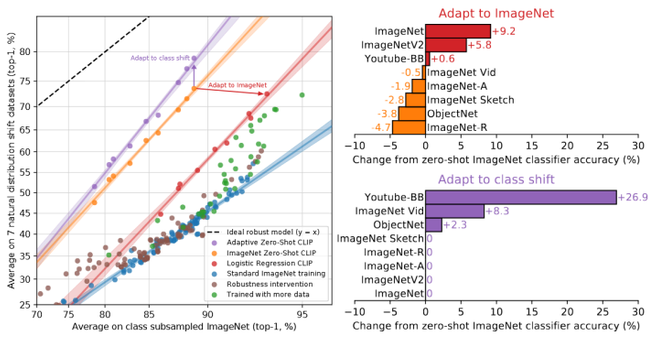


Figure 14. While supervised adaptation to ImageNet increases ImageNet accuracy by 9.2%, it slightly reduces average robustness.

▼ 왼쪽 그래프에서 각 선이 의미하는 것

- **주황색 (ImageNet Zero-Shot CLIP)**
  - 제로샷 CLIP. 점선에 가장 가깝게 붙어서 견고성이 가장 높음.
- **보라색 (Adaptive Zero-Shot CLIP)**
  - 데이터셋별로 **클래스 이름을 그 데이터셋에 맞게 맞춤 지정**한 제로샷 CLIP. 주황색보다도 더 위로 올라가서, 견고성이 **더 좋아짐**.
- **빨간색 (Logistic Regression CLIP)**
  - CLIP의 특징에 **ImageNet 데이터로 지도학습(로지스틱 회귀)을 시켜서 적응**시킨 모델. x축(ImageNet 정확도)은 크게 오르지만, 점선에서는 더 멀어짐 → 견고성 하락.
- **파란색 (Standard ImageNet training)**
  - 기존 지도학습 모델. 점선에서 가장 많이 떨어짐 → 견고성 가장 낮음.
- **갈색 (Robustness intervention)** / **초록색 (Trained with more data)**
  - 기존에 견고성을 높이려 시도했던 다른 기법들. CLIP만큼은 못 미침.

- 위로 갈수록(파란 화살표 "Adapt to class shift") **견고성이 좋아지고**,
  오른쪽으로 갈수록(빨간 화살표 "Adapt to ImageNet") **ImageNet 성능은 오르지만 견고성은 오히려 떨어짐**

Adapt to ImageNet (지도학습으로 ImageNet에 맞춤)

▼ 오른쪽 위 막대 그래프 설명

- CLIP 특징에 ImageNet 학습 데이터로 로지스틱 회귀를 훈련시켜서 **ImageNet 전용으로 튜닝**했을 때, 각 데이터셋 정확도가 제로샷 대비 얼마나 변했는지 보여줌.
- **ImageNet: +9.2%** (당연히 ImageNet 자체 성능은 크게 오름)
- **ImageNetV2: +5.8%** (ImageNet과 제작 방식이 비슷해서 같이 오름)
- **나머지 데이터셋들(ImageNet-R, ObjectNet, Sketch, A 등): 모두 마이너스(-1.9~-4.7%)**

- ImageNet에 맞추면 ImageNet은 잘하게 되지만,
  다른 낯선 데이터셋에서는 오히려 손해를 본다는 뜻.
  (일종의 과적합/좁은 특화)

Adapt to class shift (클래스 이름만 맞춤 지정)

▼ 오른쪽 아래 막대 그래프 설명

- 이건 지도학습이 아니라, **제로샷 그대로 유지하면서** 각 데이터셋의 클래스 이름을 그 데이터셋 상황에 맞게 정확히 지정

(예: Youtube-BB의 "사람" 클래스를 야구선수/신랑/다이버 등으로 억지로 풀링하지 않고, 그 데이터셋 고유의 클래스 이름을 그대로 사용)

- **Youtube-BB: +26.9%**, **ImageNet Vid: +8.3%**, **ObjectNet: +2.3%** — 큰 향상
- 나머지 데이터셋들은 원래 클래스 이름이 이미 정확해서 **변화 없음(0)**

- 자연어를 이용해 유연하게 클래스만 다시 지정해주는 것만으로도 손해 없이 성능을 더 끌어올릴 수 O

→ CLIP의 **자연어 기반 유연성**이 가진 장점을 시사함

📈 데이터 중복 분석 - 1페이지(간략하게)

> **평가용 데이터셋(예: ImageNet 테스트 사진들)이 우연히 섞여 들어가 있다면?**

- **해결 1)** 학습 전에 모든 중복을 미리 찾아서 지워버리기
  → 학습, 테스트 데이터를 **미리 다 알아야** 가능한 방법.
  나중에 새로운 평가 데이터셋이 하나 더 생기면? 그때마다 처음부터 다시 학습시켜야 하는 큰 비용 生
  → 그래서 해결 2)로 선택
- **해결 2) 중복이 실제로 얼마나 있었고, 성능에 얼마나 영향을 줬는지 측정, 그대로 공개**
  - 절차
    1. Overlap vs Clean 나누기

       ▼ 세부 내용
       - 각 평가 데이터셋의 사진들을, CLIP이 학습에 썼던 4억 개 데이터와 비교해서 "닮은 게 있는지" 자동으로 찾는 탐지기를 돌림.
       - threshold 정함
         (사람이 직접 확인해서 “이 정도 유사하면 중복이다”라는 기준선을 정함)
       - 그룹으로 나눔
         - **Overlap**: 학습 데이터와 겹치는(유사한) 사진들
         - **Clean**: 안 겹치는 나머지 사진들
         - **All**: 원래 전체 데이터셋 (Overlap + Clean)
    2. 성능 차이 측정

       ▼ 세부 내용
       - 이 세 그룹(All, Clean, Overlap) 각각에 대해 CLIP의 제로샷 정확도를 계산함.
       - **핵심 지표 = All 정확도 – Clean 정확도**
       - 만약 이 값이 양수(+)라면?
         → "겹치는 데이터 덕분에 전체 점수가 부풀려졌을 가능성"이 있다는 뜻.
    3. 통계적으로 우연이 아닌지 확인

       ▼ 세부 내용
       - 중복량 자체가 워낙 적으니
         혹시, 정확도 차이가 그냥 우연은 아닌지 통계 검정(이항 검정, 신뢰구간)까지 추가로 돌려서 확인함
  - 결과
    - 전체적으로 **겹치는 비율은 중앙값 2.2%, 평균 3.2%** 정도로 작음.
    - 이 정도 적은 중복 때문에 정확도가 0.1% 이상 변한 데이터셋은 겨우 7개뿐이고, 통계적으로 확실히 유의미한 건 그중 2개뿐.
  - 한계
    - **탐지기 자체의 한계**

      → 탐지기가 완벽하진 않음
      : 4억 개 전체를 대상으로 "놓친 중복이 없는지(재현율)"까지는 현실적으로 확인 불가능

- **"겹침"과 "안 겹침" 그룹의 성격 자체가 다를 수 있음**
  - 예를 들어 **Kinetics-700**에서 "중복"으로 잡힌 것들이 알고 보니 죄다 까만 화면(전환 프레임)이었음
    → 이런 의미 없는 프레임들이 몰려서 정확도가 뚝 떨어진 것처럼 보인 거지, 진짜 "중복 데이터 때문에 부풀려짐"과는 다른 얘기
  - **CIFAR-100**
    : 이미지 **해상도가 너무 낮아**서, 작은 새나 비행기 같은 게 실제로는 안 겹치는데 탐지기가 착각해서 겹친다고 오판한 경우가 많았음

⭐ **CLIP의 높은 제로샷 성능이 단순히 '답을 미리 봐서'가 아니라 진짜 일반화 능력에서 나온 것임**

4. Conclusion

1. 한계점

전반적 성능 격차와 스케일링의 한계

- 제로샷 CLIP은 단순한 ResNet-50 + 선형분류기 베이스라인 수준과 경쟁력이 있지만, 이건 이미 **현재 SOTA보다 한참 아래** 수준임
- CLIP이 전체 SOTA에 도달하려면 **연산량 약 1000배 증가**가 필요한데, 현재 하드웨어로는 **비현실적**
- → **결론**: 연산/데이터 효율성 개선 연구가 더 필요함

특정 과제 유형에서의 약점

- **세분화 분류**(자동차 모델, 꽃 품종, 항공기 기종)에서 성능 저조
- **추상적/체계적 과제**(물체 개수 세기)에서도 약함
- 사전학습 데이터에 거의 없을 법한 **완전히 새로운 과제**(차량 간 거리 추정)에서는 거의 무작위 수준
  → 아직 CLIP이 거의 못 푸는 과제가 **매우 많을 것**이라 예상

진짜 분포 밖(OOD) 데이터에는 여전히 취약 (MNIST 사례)

- 렌더링된 디지털 텍스트(OCR)는 잘하지만, 손글씨 숫자(MNIST)는 88%에 그침
  — 원본 픽셀 기반 단순 로지스틱 회귀보다도 못함
- 이유: 사전학습 데이터(4억 장)에 MNIST와 닮은 이미지가 거의 없었기 때문

  → **핵심 통찰**: CLIP은 "일반화의 근본 문제"를 해결한 게 아니라, **"데이터를 워낙 크고 다양하게 모으면 웬만한 건 다 분포 안에 들어오겠지"라는 순진한 가정**으로 문제를 우회한 것뿐. MNIST가 이 가정이 쉽게 깨질 수 있음을 보여줌

제로샷 분류기의 근본적 한계 (열린 어휘 생성 불가)

- CLIP은 **주어진 클래스 후보들 중에서만** 선택 가능 — 이미지 캡셔닝처럼 완전히 새로운 문장을 생성하는 것보다 유연성이 떨어짐
- 캡션 생성 방식은 시도해봤지만 CLIP보다 **연산 효율이 훨씬 낮아서** 채택 안 함
- **향후 방향 제안**: 대조학습 + 생성모델을 함께 학습시키거나, 추론 시점에 여러 자연어 설명을 탐색하는 방식 (Andreas et al., 2017 참고)

딥러닝 고질적 문제인 데이터 비효율성은 해결 못 함

- CLIP은 데이터 효율성 문제를 "해결"한 게 아니라 그냥 **압도적으로 많은 데이터(수억 장)로 밀어붙여서 보완**한 것
- 32 에폭 동안 학습에 쓰인 128억 장 이미지를 초당 1장씩 본다고 가정하면 **405년**이 걸리는 규모

  → 자기지도학습, 자기학습(self-training) 같은 기법과 결합하면 데이터 효율성을 개선할 여지가 있음

자연어 인터페이스 자체의 한계 + 퓨샷 전환 시 역설적 성능 하락

- 복잡한 개념은 애초에 **텍스트만으로 설명하기 어려움** — 실제 학습 예시가 유용한 건 부정할 수 없음
- 그런데 CLIP은 퓨샷 성능을 **직접 최적화하도록 설계되지 않음** — 현재는 그냥 특징 위에 선형분류기를 얹는 방식으로 처리
- **직관에 반하는 문제**: 제로샷 → 퓨샷(1-shot)으로 전환할 때 오히려 **성능이 떨어지는 현상** 발생 (앞서 봤던 그림 6과 연결됨)
- 이는 사람이 예시를 1개만 봐도 성능이 확 오르는 것과 **정반대** 양상

- → 향후 CLIP의 강력한 제로샷 성능과 효율적인 퓨샷 학습을 **결합하는 방법**이 필요

사회적 편향 문제

- 인터넷에서 **필터링 없이** 긁어온 이미지-텍스트 쌍으로 학습했기 때문에, CLIP은 **많은 사회적 편향을 그대로 학습**함
- 이는 이전 이미지 캡션 모델 연구(Bhargava & Forsyth, 2019)에서도 이미 보고된 문제
- → 상세 분석과 완화 전략은 **7절**에서 다룸

▼ Bias

실험 1: FairFace 벤치마크 기본 성능

- **LR CLIP**(CLIP 특징 + 지도학습 분류기)이 Instagram 모델, FairFace 자체 모델보다 대체로 **더 정확함**
- 성별 분류는 모든 인종 카테고리에서 **95% 이상**으로 높음
- 단, 벤치마크 정확도가 높다고 해서 **실제 배포 시 공정성이 보장되는 건 아님** (정확도 ≠ 공정성)

실험 2: 폄하(denigration) 편향 조사

FairFace 이미지에 '동물', '고릴라', '도둑', '범죄자' 등 자극적 클래스를 섞어서 분류시킴:

- 전체 **4.9%**가 비인간(동물류) 클래스로 오분류
  - 그중 **흑인 이미지가 약 14%**로 가장 높음 (다른 인종은 8% 미만)
  - **0~20세**가 가장 높은 비율(14%)로 동물류 오분류
- 남성의 **16.5%**가 범죄 관련 클래스로 분류 (여성은 9.8%)
  - **0~20세**가 범죄 관련 분류 비율 가장 높음(18%), 70세 이상은 0%
- **'어린이(child)' 클래스를 추가**하자 → 젊은 층의 동물/범죄 오분류가 **극적으로 감소**
  → **클래스 설계 자체가 편향 발생의 핵심 변수**임을 입증

실험 3: 국회의원 이미지로 성별·직업 편향 테스트

- 성별 분류 정확도: **100%** (FairFace보다도 높음 — 이미지 품질이 좋아서로 추정)
- **낮은 임계값(0.5%)**: 여성 → '유모', '가사도우미' / 남성 → '죄수', '폭력배' 같은 성별 고정관념적 라벨 등장
- **높은 임계값(4%)**: 이런 편향은 줄고 '입법자' 같은 중립적 라벨이 상위권
- 외부 API(Google/Amazon/Microsoft) 통합 라벨셋 테스트:
  - 여성 → 머리카락/외모 관련 라벨('금발' 등) 편중
  - 남성 → '임원', '의사' 등 **고지위 직업** 라벨 편중
  - 여성에게 더 많이 붙은 직업은 '뉴스캐스터', '판사' 등 소수뿐
  - 임계값을 낮추면 남성 라벨도 '정장', '넥타이' 같은 **외모 중심**으로 바뀜(단, 역방향은 성립 안 함)

→ 클래스 설계·임계값 설정 같은 사소해 보이는 선택들이 **모델이 드러내는 편향의 종류와 정도를 크게 좌우**함

2. 결론

- NLP에서 성공을 거둔 과제 비종속적(task-agnostic) 웹 규모 사전 학습을
  → 다른 도메인으로 전이할 수 있는지를 조사 (컴퓨터 비전)
- 많은 기존 데이터셋으로의 제로샷 전이 O
- 충분한 규모에서는 이 접근법의 성능이 과제별 지도 학습 모델과 경쟁력 有