week 11 SAM

1. Abstract

- Segmentation을 위한 새로운 task, 모델, 데이터셋 소개
- SAM(Segmentation Anything Model)
- SA-1B
  — 1,100만 개 이미지로 구성

2. Introduction

> 🎯 **image segmentation을 위한 foundation model 구축**
> → 프롬프트 엔지니어링 활용
> → 새로운 데이터 분포에 대한 다양한 다운 스트림 분할 문제 해결

- **task**
  - 어떤 분할 프롬프트가 주어지더라도 유효한 segmentation mask 반환
- **model**
  - 유연한 프롬프트 지원
  - interactive 사용을 위해 실시간으로 마스크 계산 O
  - 모호성 인지
- **dataset**
  - 1,100만 개의 라이선스
  - 개인정보를 보호하는 이미지로부터 얻은 10억 개 이상의 마스크 포함

3. Method

1. Segment Anything Task

- **태스크**
  - 점·박스·마스크·텍스트 등 어떤 프롬프트에도 유효한 분할 마스크를 반환하는 "프롬프트 가능한 분할 태스크" 정의
    (모호해도 하나의 대상에 대해 합리적인 마스크면 충분)
- **사전학습**
  - 프롬프트 시퀀스를 시뮬레이션해 학습시키되,
    인터랙티브 분할과 달리 모호한 상황에서도 항상 유효한 마스크 예측을 목표로 함
- **제로샷 전이**
  - 별도 학습 없이 프롬프트 엔지니어링만으로 다양한 다운스트림 분할 태스크 해결 가능
  - 예: 검출기 출력을 프롬프트로 활용
- **관련 태스크와의 차이**
  - 기존 다중 태스크 시스템은 고정된 태스크 집합만 처리하지만,
    본 모델은 다른 모듈과 결합해 학습 시 보지 못한 새로운 태스크도 수행 (태스크 일반화)
- **의의**
  - 프롬프팅과 모듈 결합을 통해 하나의 모델이 설계 당시 예상 못한 태스크까지 확장 가능 (CLIP-DALL·E와 유사한 구조)

2. Segment Anything Model

- **구성 요소 개요**

    - 이미지 인코더, 프롬프트 인코더, 마스크 디코더
    - Transformer 기반 비전 모델을 (상각) 실시간 성능에 맞게 조정하여 구축함
- **이미지 인코더**
    - 고해상도 입력에 맞게 최소 수정된 MAE 사전학습 ViT를 사용하며, 이미지당 한 번만 실행되어 프롬프팅 이전에 미리 계산 가능
- **프롬프트 인코더**
    - 점·박스는 위치 인코딩+학습된 임베딩
    - 텍스트 — CLIP 텍스트 인코더로
    - 마스크(밀집 프롬프트) — 합성곱으로 임베딩

      → 이미지 임베딩과 결합
- **마스크 디코더**
    - 수정된 Transformer 디코더 블록(양방향 교차 주의 포함)과 동적 마스크 예측 헤드를 통해 이미지·프롬프트 임베딩·출력 토큰을 마스크로 매핑
- **모호성 해결**
    - 하나의 프롬프트에 대해 3개의 마스크(전체·부분·하위부분)를 예측

      → 평균화 문제를 방지하고, 각 마스크의 신뢰도(추정 IoU)를 함께 예측
- **효율성**
    - 프롬프트 인코더와 마스크 디코더는 CPU·웹 브라우저에서 약 50ms 만에 실행되어 실시간 인터랙티브 사용이 가능
- **손실 함수 및 학습**
    - focal loss와 dice loss의 선형 결합으로 학습
    - 마스크당 11라운드의 무작위 프롬프트 샘플링으로 인터랙티브 환경을 시뮬레이션해 데이터 엔진과 통합

4. Experiments

자동 생성 마스크의 품질 (IoU 기준)

- SA-1B 마스크의 **99.1%가 완전 자동으로 생성**되었는데, 이 자동 마스크와 전문가가 수정한 마스크를 비교한 결과:
    - **94%의 쌍이 90% 이상의 IoU**를 기록
    - 이는 기존 연구에서 보고된 **사람 간(annotator-to-annotator) 일치도(85~91% IoU)보다 높은 수준**

→ SAM이 사람 개입 없이 자동으로 만든 마스크가 사람 annotation들끼리의 합의 수준보다도 더 신뢰할 만하다는 것을 의미하며,
이것이 **10억 개 규모의 SA-1B 데이터셋 전체가 자동 생성 마스크만으로 구성되어도 문제없다는 근거**가 되는 핵심 지표입니다.

5. Conclusion

1. 한계점

- 미세 구조 누락, 작은 분리된 구성 요소를 잘못 생성(hallucination)하는 경우 존재
- "확대(zoom-in)" 기반 정밀 기법 대비 경계가 덜 선명함
- 점이 많이 주어지는 경우 전용 인터랙티브 분할 기법이 SAM보다 우수 (SAM은 범용성 중심 설계)
- 무거운 이미지 인코더 사용 시 전체 파이프라인은 완전한 실시간은 아님
- text-to-mask는 아직 탐색적 수준, 완전히 견고하지 않음
- 시맨틱/파놉틱 분할을 위한 간단한 프롬프트 설계 방법은 불명확
- 특정 도메인 특화 도구들은 해당 도메인에서 SAM보다 우수할 것으로 예상

2. 결론

- 새로운 태스크(프롬프트 가능한 분할), 모델(SAM), 데이터셋(SA-1B)을 통해 이미지 분할을 파운데이션 모델 시대로 확장하려는 시도

- SAM이 실제로 파운데이션 모델의 지위를 얻을지는 커뮤니티의 활용 방식에 달려 있음
- 10억 개 이상의 마스크 공개와 프롬프트 가능한 분할 모델이 향후 연구의 토대가 되기를 기대