week 12 - Genie

📄 **Genie: Generative Interactive Environments** (Bruce et al., Google DeepMind, ICML 2024)
arxiv.org/abs/2402.15391

1. Abstract

⭐ 행동(action) 라벨이 없는 인터넷 비디오만으로, 사용자가 **프레임 단위로 조작(play)할 수 있는 가상 환경**을 생성할 수 있는가?

- **Genie**
  : 라벨 없는 인터넷 비디오로 **비지도 학습**된 최초의 생성형 상호작용 환경(Generative Interactive Environment)
- 텍스트, 합성 이미지, 사진, 손그림 스케치 등으로 프롬프트하면 **행동으로 조작 가능한 가상 세계**를 생성
- 파라미터 수 **11B**, **Foundation World Model**로 볼 수 있음
- 구성

  ① 시공간 비디오 토크나이저

  ② 자기회귀 Dynamics Model

  ③ 단순하고 확장 가능한 Latent Action Model
- Ground-truth 행동 라벨이나 도메인 특화 요구사항 없이 프레임 단위 제어 가능
- 학습된 잠재 행동 공간으로 **처음 보는 영상에서 에이전트가 행동을 모방**하도록 학습 가능
  → 범용 에이전트 학습의 가능성

2. Introduction

⭐ 기존 World Model은 **행동 라벨이 붙은 데이터**가 필요한데, 방대한 인터넷 비디오에는 행동 라벨이 없음 — 연구 동기

배경

- 생성형 AI는 텍스트·이미지 생성에서 큰 발전, 비디오 생성도 빠르게 발전 중
- 하지만 비디오 모델과 **사용자가 직접 행동을 입력해 상호작용하는 경험** 사이에는 큰 간극이 존재

문제점

- 기존 World Model은 (관측, 행동) 쌍 데이터가 필요 → 행동 라벨 수집 비용이 큼
- 인터넷에는 방대한 비디오가 있지만 **행동 라벨이 없음**

제안

- 인터넷 비디오만으로 학습하는 새로운 패러다임 **"Generative Interactive Environments"** 제안
- 2D 플랫포머 게임 영상 **20만 시간 이상**을 수집·필터링하여 학습
- **핵심 아이디어**
  : 프레임 사이 변화를 설명하는 **이산적 잠재 행동(latent action)** 을 비지도로 학습
  → 사용자가 이 잠재 행동을 입력해 환경을 조작

3. Related work

분야	대표 연구	한계 / Genie와의 차이
World Models	Ha & Schmidhuber(2018), Dreamer 계열, GAIA-1, UniSim	학습 시 **행동 라벨이 필요**함

분야	대표 연구	한계 / Genie와의 차이
Video Models	Phenaki, MaskViT, VideoPoet 등	비디오 전체 수준의 텍스트 제어만 가능, **프레임 단위 제어 불가**
Playable Video Generation	PVG (Menapace et al., 2021)	잠재 행동을 쓰지만 **특정 도메인 한정**, 새로운 환경 생성 불가
Environment Generation	절차적 콘텐츠 생성(PCG), GameGAN	게임 엔진/행동 데이터 필요, 범용성 부족
비디오로부터 에이전트 학습	VPT, ILPO, LAPO 등	VPT는 라벨 데이터로 IDM(역동역학 모델) 학습 필요

→ Genie는 ① **비디오만으로 학습** ② **프레임 단위 제어** ③ **범용성**을 모두 만족

4. Method

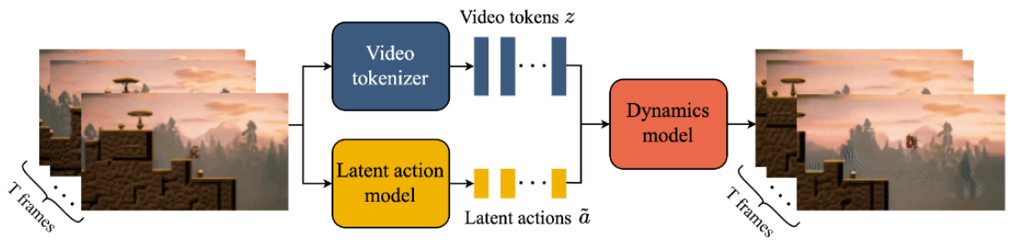


Figure 3 | Genie model training

1. 전체 구조

- 3개 구성요소 모두 **ST-Transformer** 기반

```
입력 비디오 x_1:T
   ├→ (1) Latent Action Model (LAM)  → 잠재 행동 a_1:T-1   (8개 이산 코드)
   └→ (2) Video Tokenizer            → 비디오 토큰 z_1:T
          (3) Dynamics Model ( z_1:t-1, ã_1:t-1 ) → 다음 프레임 토큰 ẑ_t
```

- 학습: Video Tokenizer 먼저 학습 → 이후 LAM과 Dynamics Model을 **공동 학습(co-training)**
- 추론: 이미지 x_1 → 토큰화 → 사용자가 0–7 중 행동 선택 → Dynamics Model이 다음 프레임 예측 → 반복(자기회귀)

2. ST-Transformer

- 모든 토큰에 full attention을 하면 연산량이 비디오 길이에 따라 **제곱으로 증가**
- 해결: 각 블록을 다음처럼 분리
  - **Spatial attention**: 한 프레임 내 1×H×W 토큰끼리 attention
  - **Temporal attention**: 같은 공간 위치의 T×1×1 토큰끼리, **causal mask** 적용
  - FFW는 공간·시간 attention 뒤 **하나만** 사용
    (공간 FFW 생략 → 다른 구성요소 스케일업에 연산 투자)
- 연산량이 프레임 수에 대해 **선형**으로 증가 → 긴 비디오 생성에 유리

3. Latent Action Model (LAM)

- 목적: 행동 라벨 없이 **프레임 간 변화를 일으키는 "행동"을 비지도 학습**
- **Encoder**
  : 이전 프레임들 x_1:t와 다음 프레임 x_t+1을 입력받아 연속 잠재 행동 출력
- **Decoder**
  : 이전 프레임들 + 잠재 행동만 받아 다음 프레임 x̂_t+1 재구성
- **VQ-VAE** 목적함수로 학습, 코드북 크기를 **8개**로 제한
  - 사람이 조작하기 쉽도록 행동 수를 적게 제한
  - Decoder는 과거 프레임과 행동만 볼 수 있으므로, 잠재 행동이 **과거와 미래 사이의 가장 의미 있는 변화**를 담도록 강제됨

- **추론 시에는 LAM을 버리고 VQ 코드북만 사용** → 사용자가 직접 행동 코드를 입력
- 입력은 토큰이 아닌 **원본 픽셀** 사용 (ablation에서 더 좋은 제어 가능성 확인)

4. Video Tokenizer

- 비디오를 이산 토큰으로 압축 → 차원을 줄이고 생성 품질을 높임
- **VQ-VAE** + ST-Transformer (**ST-ViViT**)
- 인코더·디코더 모두 temporal 정보를 사용
  → 각 토큰 z_t가 x_1:t의 정보를 담음 (시간적 일관성 향상)
- 공간 정보만 쓰는 ViT보다 품질↑, full attention 기반 C-ViViT보다 **연산 효율↑**

5. Dynamics Model

- **Decoder-only MaskGIT** Transformer
- 입력
  : 과거 프레임 토큰 $z_{1:t-1}$ + (stop-gradient 된) 잠재 행동
  → 출력: 다음 프레임 토큰 $\hat{z}_t$
- Cross-entropy loss로 학습,
  입력 토큰을 **Bernoulli 분포(마스킹 비율 0.5–1 균등 샘플)** 로 랜덤 마스킹
- 잠재 행동은 concat이 아닌 **additive embedding**으로 더함
  → 제어 가능성 향상
- 학습 안정화: **bfloat16 + QK norm**
- 추론: MaskGIT 샘플링 25 step, temperature 2

5. Experiments

1. 데이터셋

- **Platformers**
  : 2D 플랫포머 게임 영상 5,500만 클립(24.4만 시간)
  → 품질 분류기로 필터링 후 **680만 개의 16초 클립(3만 시간)**, 10 FPS, 160×90 해상도
- **Robotics**
  : RT-1 데이터셋 등 (**행동 라벨 없이 비디오만 사용**)

2. 평가 지표

- **Video fidelity**: FVD (Fréchet Video Distance), 낮을수록 좋음
- **Controllability**:$\Delta_t PSNR$

$$\Delta_t \text{PSNR} = \text{PSNR}(x_t, \hat{x}_t) - \text{PSNR}(x_t, \hat{x}'_t)$$

- $\hat{x}_t$: 실제 영상에서 추출한 잠재 행동으로 생성 / $\hat{x}'_t$: **랜덤 잠재 행동**으로 생성
- 값이 클수록 잠재 행동이 생성 결과에 큰 영향 = 제어 가능성이 높음

3. 스케일링 결과

- Dynamics Model을 **40M** → **2.7B**로 키우며 실험
  → 모델 크기가 커질수록 최종 loss가 **꾸준히 감소**
- 배치 크기를 키워도 성능 향상
- 이를 바탕으로 최종 **Genie 11B** 학습
  (Tokenizer 200M, LAM 300M, Dynamics 10.1B / TPUv5p 256개, 약 9,420억 토큰)

4. 정성적 결과

- **OOD 프롬프트 일반화**
  : 텍스트→이미지 생성 이미지, 손그림 스케치, 실제 사진을 입력해도 플레이 가능한 환경으로 변환
- 각 잠재 행동이 서로 다른 입력에서도 **일관된 의미**(왼쪽 이동, 오른쪽 이동, 점프 등)를 가짐

- **창발적 능력**
  : 캐릭터 이동에 따른 **시차(parallax) 효과**, 변형 가능한 물체 시뮬레이션
- **Robotics**
  : 로봇 팔 이동 등 일관된 잠재 행동 학습, 물체 변형 같은 물리적 특성도 모사

5. 에이전트 학습 (Behavioral Cloning)

- 처음 보는 **CoinRun** 환경의 전문가 영상에 LAM을 적용해 잠재 행동 라벨 생성 → 이를 예측하는 정책(policy) 학습
- 잠재 행동 → 실제 행동 매핑은 **소량(약 200개)의 라벨 데이터**만으로 학습
- 결과
  : 실제 행동 라벨 전체를 쓰는 **Oracle BC 에이전트와 비슷한 성능**

  → 인터넷 비디오로부터 범용 에이전트를 학습할 가능성 제시

6. Ablation

Latent Action Model 입력 (토큰 vs 픽셀)

	Dataset	#Params	FVD (↓)	Δ_tPSNR(↑)
Token-input	Platformers	2.3B	**38.8**	1.33
Pixel-input (Genie)	Platformers	2.5B	40.1	**1.91**
Token-input	Robotics	1B	257.8	1.65
Pixel-input (Genie)	Robotics	1B	**136.4**	**2.07**

Table 2 | Latent action model input ablation.

→ 픽셀 입력이 제어 가능성에서 확실히 우세 (토큰화 과정에서 미세한 움직임 정보가 손실되기 때문)

Tokenizer 구조

	#Params	Memory	FVD (↓)	Δ_tPSNR(↑)
ViT	230M	0.3GB	114.5	1.39
C-ViViT (Villegas et al., 2023)	225M	1.6GB	272.7	1.37
ST-ViViT (ours)	205M	0.9GB	**81.4**	**1.66**

Table 3 | Tokenizer architecture ablation

→ ST-ViViT가 품질·제어성 모두 최고이면서 메모리 효율도 좋음 (C-ViViT는 과적합 경향)

6. Conclusion

⭐ **행동 라벨 없이(video-only)** 학습 + **프레임 단위 제어** + **도메인에 국한되지 않는 일반성**을 동시에 달성

1. 한계점

- **환각(hallucination)**
  : 자기회귀 Transformer 특성상 비현실적인 미래를 생성할 수 있음
- **짧은 메모리**
  : 16프레임 문맥만 사용 → 긴 시간 동안 일관된 환경 유지가 어려움
- **느린 추론 속도**
  : 약 **1 FPS** 수준 → 실시간 상호작용에는 아직 부족
- 학습 데이터가 2D 플랫포머 게임 위주 (도메인 확장 필요)

2. 결론

- 라벨 없는 인터넷 비디오만으로 학습한 **최초의 Generative Interactive Environment, Genie** 제안
- 이미지 한 장으로 **플레이 가능한 가상 세계**를 생성하며, 잠재 행동이 비지도 학습만으로 일관된 의미를 가짐
- 게임뿐 아니라 로봇 영상에도 적용 가능한 **일반적인 방법론**

- 향후 방향
  : 더 큰 규모의 인터넷 비디오로 학습해 더 다양하고 사실적인 환경 생성, **범용 에이전트 학습을 위한 무한한 환경 생성기**로 활용